西 北 工 业 大 学

研究生学位论文开题报告表

攻读学位级别： √博士 □硕士

学　　院　电子信息学院

姓　　名　孙国栋

学　　号　2025100353

学科、专业　信息与通信工程

指导教师　戴玉超

填表日期　2026 年 10 月 22 日

西北工业大学研究生院

研究生学位论文开题报告的要求

一、硕士生的开题报告内容应包括文献综述、选题意义、研究内容、研究方案，论文工作量的估计、工作条件，预期达到的水平，存在的问题及拟采取的解决措施。

二、博士生的开题报告内容应包括文献综述、选题背景及其意义、研究内容、研究特色、工作难点、预期成果及其可能的创新点。

三、正式开题之前，研究生应在广泛阅读中、外文资料的基础上，深入了解拟选课题的国内外研究动态，把握所选课题的目的、意义和预期结果，明确课题工作的设想、方法和研究路径。

四、博士生在规定的时间内，写出开题报告初稿，经指导教师审阅同意后，进行开题报告的送审。开题报告评审未通过者，修后重新送审，若第二次送审仍通不过者，则按有关规定终止学籍。

五、不能按期申请开题评议者，应及时向学院提出延期申请。

六、本表若不够填写时，可另加附页。

论文题目	连续动态世界模型构建方法研究			
开题次数	√ 第一次　　□ 第二次			
论文类型 （请在有关项目下作 √ 记号）	基础研究	应用研究	工程技术	跨学科研究
	√			

一、学位论文研究依据

学位论文的选题依据和研究意义，国内外研究现状和发展态势，主要参考文献，以及已有的工作积累和研究成果。

（图、文、参考文献格式参照《西北工业大学博士研究生学位论文编写规则》）

1.1　选题依据及研究意义

世界模型（World Model）是智能体通过环境观测与交互经验建立的、用于表征外部世界状态及预测其演化规律的内部模型 [1-2]。现实环境持续变化，而智能体通常只能获得离散且不完整的观测信息，因此需要结合历史观测与交互经验，形成并维护对当前环境状态的内部估计，而非仅依赖单次观测进行判断。如图 1 所示，世界模型通过感知信息持续更新内部状态，并在给定动作等条件下推演未来可能的环境变化；智能体则利用预测结果进行规划与行动，再通过实际执行反馈修正内部状态，形成感知、预测与行动相互联系的闭环。世界模型的内部状态可以采用潜在变量、视觉特征或显式三维结构等不同形式，其核心价值在于建立能够反映环境状态与变化规律、支持未来预测的内部表征，为智能体从被动感知走向主动理解与自主交互提供基础。

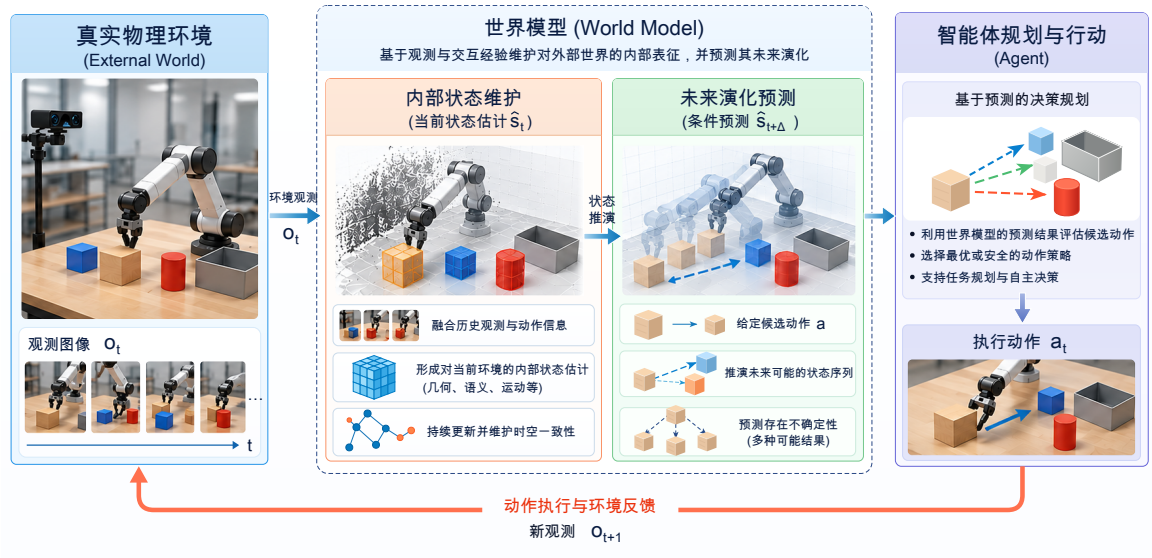


图 1 世界模型与智能体的感知—预测—行动闭环示意

世界模型已成为国际人工智能领域的重要前沿研究方向，也是推动人工智能从信息感知与内容生成走向物理世界理解、动态预测和自主决策的重要技术。国家自然科

学基金委员会于 2026 年发布“空间智能与世界模型”专项项目申请指南，推动相关基础理论与关键技术研究 [3]；美国国家科学基金会（NSF）通过 CAREER 项目支持世界模型与机器推理等方向的研究 [4]。工业界也在积极探索世界模型的技术潜力，Google DeepMind 推出 Genie 3，能够生成可实时交互的动态虚拟环境，探索世界模拟与智能体交互的结合 [5]；NVIDIA 发布 Cosmos 世界基础模型平台，面向机器人和自动驾驶等物理智能应用，支持环境生成与仿真研究 [6]。这些科研布局与技术进展体现了世界模型在新一代人工智能基础研究和实际应用中的重要地位。

面向航天器在轨维护、无人系统自主作业等复杂任务，智能体需要在有限观测条件下持续理解动态环境，并预测自身行为可能引起的变化。美国国家航空航天局（NASA）开展的机器人在轨加注任务（Robotic Refueling Mission，RRM）为此类应用提供了实际案例：该项目利用国际空间站上的 Dextre 机器人，在地面远程操控下完成了保护覆层切割与翻起、线缆剪切、盖帽拆卸及阀门操作等技术演示，验证了复杂在轨机器人服务操作的可行性 [7]。面向此类任务的进一步自主化，如图 2 所示，世界模型需要具备四方面能力：（1）**连续时间建模**，现实中的运动连续发生，而视觉观测通常离散采集，需要恢复观测间的连续状态；（2）**对象时空一致性**，机械臂操作产生的遮挡、共动与局部形变，要求持续维持对象身份、归属及跨时刻关联；（3）**物理连接变化建模**，切割、分离等操作可能改变原有物理连接，需要及时更新内部结构，并区分真实边界形成与已有表面重新显露；（4）**动作后果预测**，执行牵引等动作前，需要预测当前运动与结构状态下可能产生的后续响应。上述四项能力共同构成面向在轨维护任务的动态环境建模需求。



图 2 面向在轨维护任务的世界模型动态环境建模需求

世界模型已在潜在状态预测、三维动态场景表征及动作条件演化预测等方面取得重要进展，但面对观测不完备、结构持续变化的复杂物理环境，仍存在以下局限：（1）**连续状态恢复受限**：离散观测难以充分约束非采样时刻的真实运动 [8]；（2）**对象时空关联不稳定**：遮挡、共动及形变容易引起对象归属歧义 [9]；（3）**物理结构变化适应不**

足：连接关系改变后，局部结构更新与有效历史延续难以兼顾 [10]；（4）**动作响应预测仍有局限：**如何充分利用已有运动及当前有效物理结构信息，提高复杂动态条件下的预测准确性，仍有待进一步研究 [11-12]。

在导师承担的国家自然科学基金项目与联合基金项目支持下，本课题面向复杂动态环境中有限视觉观测下的状态建模与演化预测需求，开展连续动态世界模型构建方法研究。课题拟研究动态场景中连续运动、空间组织及物理连接关系的协同表征，建立能够随新观测持续修正的三维动态状态，并进一步探索基于该状态的动作后果预测方法，形成贯通环境感知、动态表征与未来演化预测的模型构建框架。研究有望为复杂动态环境中的时空一致性建模和动作响应预测提供方法基础，并为空天无人系统自主作业、航空航天装备智能维护及虚拟试验训练等应用提供技术支撑。

1.2 国内外研究现状及发展态势

连续动态世界模型的构建涉及状态恢复、演化预测与动作学习，相关研究主要分布于四维动态场景重建、世界模型和具身操作中的动作学习。四维重建从视觉观测恢复几何、外观及时空变化；世界模型学习内部状态及演化规律并推演未来；动作学习根据观测与任务信息生成动作，部分方法进一步利用环境预测辅助决策。三者分别在空间表征、时序建模和预测反馈上提供基础，并逐步融合。

1.2.1 四维动态场景重建

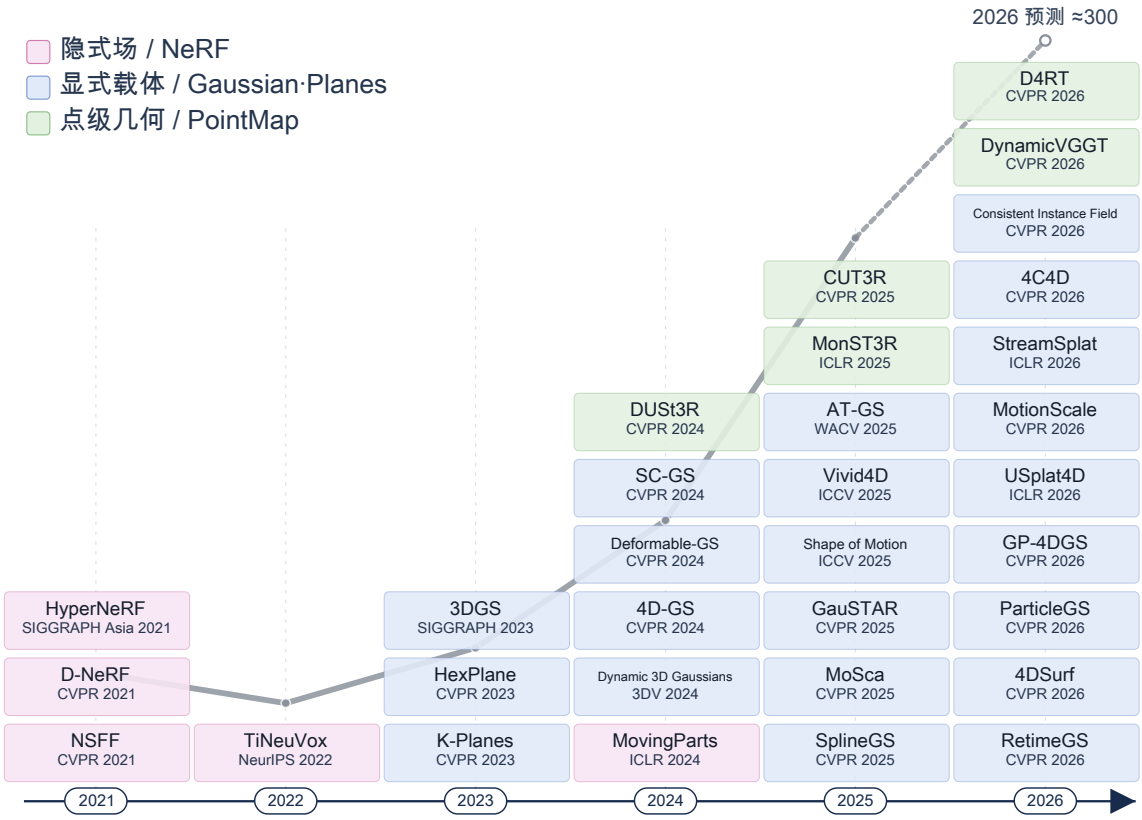


图 3 四维动态场景重建的代表性工作与发展脉络

四维动态场景重建旨在从图像或视频观测中恢复三维场景的几何、外观及其时间变化，为新视角合成、运动分析和动态状态建模提供基础。随着神经隐式场、显式图元及学习式几何模型的发展，相关研究逐渐从动态几何恢复拓展到连续运动表达、跨时刻空间关联与结构更新 [13-15]。图 3 按隐式场、显式图元和点级几何三类汇总了 2021—2026 年的代表性工作。三类方法具有不同的表示特点，也可相互结合，共同推动动态场景重建技术的发展。

隐式场表征主要利用连续函数描述场景几何与外观，并通过时间条件或空间变形建立不同时刻的联系。早期 DynamicFusion 通过非刚性变形实现动态表面的融合与跟踪 [16]；在 NeRF 基础上 [17]，D-NeRF、Nerfies 和 NSFF 分别通过规范空间映射、形变场及场景流描述动态场景 [18-20]，HyperNeRF 进一步利用高维表示适应复杂拓扑变化 [21]。这类方法具有灵活的连续空间表达能力，但其运动恢复仍受观测覆盖、时序对应及形变假设约束，连续函数表示并不意味着非采样时刻的真实运动已被充分确定。

显式图元表征将场景组织为可直接操作的点、面元或高斯图元，在动态重建中兼顾表示效率与几何可操作性。3D Gaussian Splatting（3DGS）建立了高效的显式高斯表示与可微渲染基础 [22]；Dynamic 3D Gaussians、4D-GS、Deformable 3D Gaussians 和 SC-GS 分别探索持久图元跟踪、时间条件变形及稀疏运动控制 [23-26]。在此基础上，RetimeGS、SplineGS 和 ParticleGS 进一步研究连续时间重建、运动样条表达与物理运动外推 [8, 27-28]，推动动态表示从离散帧拟合向连续运动建模发展。

除运动表达外，显式重建也逐渐关注场景单元之间的空间组织、结构变化及观测不确定性。MoSca、Shape of Motion 和 MovingParts 利用运动线索组织跨时刻几何与部件关系 [29-31]，Consistent Instance Field 通过概率式时空表示维护对象身份与可见性关系 [9]。GauSTAR 结合表面跟踪与局部重建适应几何拓扑变化 [10]，USplat4D 则利用时变不确定性引导可靠运动信息传播 [32]。这些研究拓展了显式动态表征的能力，但几何拓扑更新、对象身份关联与真实物理连接状态具有不同含义，遮挡造成的表面显露也不等同于物理连接改变，相关信息仍需结合观测证据加以区分。

随着视觉基础模型的发展，**点级几何表征**逐渐成为动态场景重建的重要技术路线，相关学习式方法能够从图像或视频中直接预测三维几何及跨时刻对应。DUSt3R 和 VGGT 为点图、深度及相机参数的联合预测提供了基础 [33-34]；MonST3R 将学习式几何恢复扩展到动态视频 [35]，CUT3R 通过持久状态支持连续三维感知 [36]，D4RT 则利用统一的时空查询机制恢复动态几何与对应关系 [37]。此类方法提高了复杂观测条件下几何与运动信息的获取能力，为动态场景重建提供了重要先验，但如何将预测结果组织为时空一致、可随新观测持续修正的场景状态，仍有进一步研究空间。

总体来看，隐式场提供灵活的连续表达，显式图元支持高效重建与局部操作，点级几何方法推动了学习式几何和运动恢复。DyCheck、TAP-Vid、TAPVid-3D 和 PointOdyssey 等基准从动态重建、二维及三维点跟踪等不同方面提供了评价依据 [38-41]。现有研究已在连续运动、空间关联和结构适应方面取得进展，但在有限观测条件

下，如何协调运动恢复、对象空间组织与结构变化，形成可持续维护且保留有效历史信息的动态场景表征，仍是值得进一步研究的问题。

1.2.2 世界模型

世界模型通过环境观测与交互经验建立内部状态，并学习其演化规律，以支持未来预测与决策。根据内部状态的表示形式和预测目标，相关研究逐渐形成潜在状态与动力学模型、视觉表征预测模型、生成式世界模拟模型，以及三维结构与物理世界模型等技术路线。图 4 汇总了 2018—2026 年的代表性工作，并标注了对 2026 年相关论文数量的预测。OpenAlex 的相关检索统计可用于观察领域发展趋势，但检索结果包含预印本、综述和应用论文，不等同于人工筛选的正式论文总数 [42]。随着强化学习、自监督学习和生成式模型的发展，世界模型的研究逐步从紧凑潜在状态预测拓展到视觉环境生成、三维空间表征及物理动态模拟。

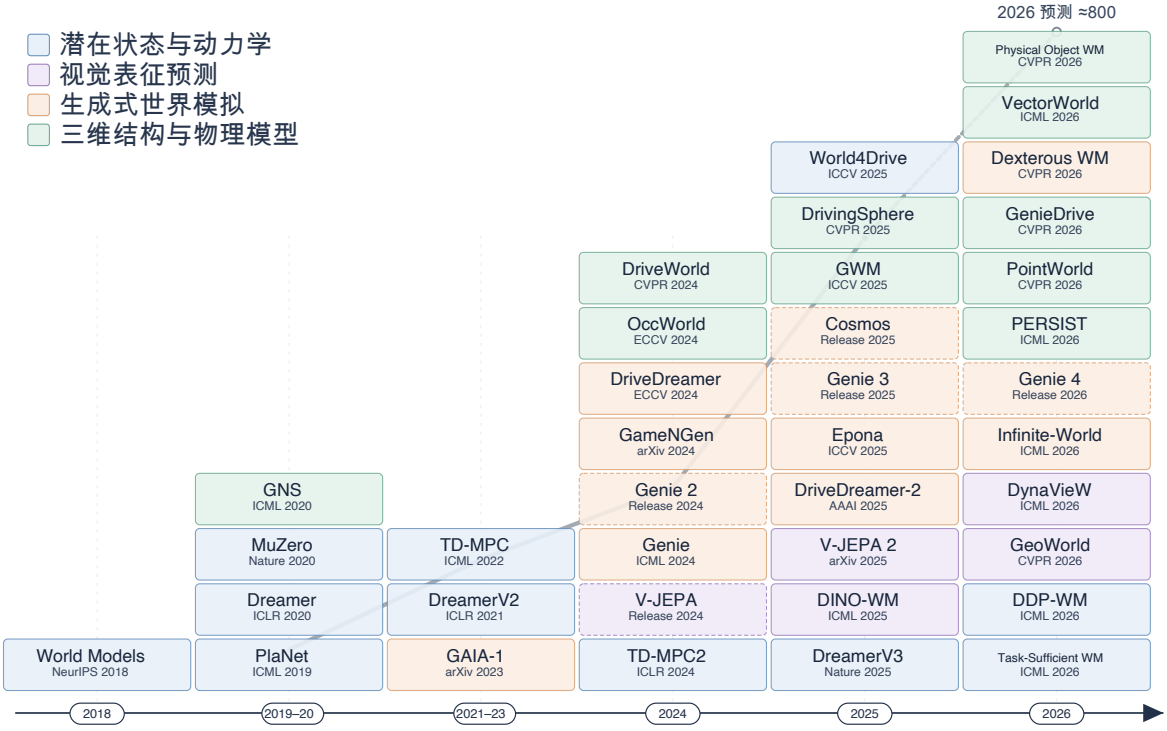


图 4 世界模型的代表性工作与研究发展趋势

潜在状态与动力学模型通常将历史观测和动作编码为紧凑的潜在状态，并学习其动态转移规律。World Models[1]、PlaNet[43] 和 Dreamer[44] 分别通过循环记忆、潜在空间规划和想象轨迹学习环境动态；MuZero[45] 进一步学习与规划相关的奖励、价值及策略信息。PETS[46]、TD-MPC2[47] 和 DreamerV3[2] 在不确定性建模、连续控制和多任务学习方面取得进展，Task-Sufficient World Models[48] 则强调保留对任务决策充分的状态信息。这类方法为环境预测与规划提供了重要基础，但其潜在状态主要受到任务目标约束，并不必然具有明确的三维几何、对象关联及物理结构含义。

视觉表征预测模型利用视觉特征或对象级表示描述环境状态，并在表征空间中预测未来变化。I-JEPA[49] 通过联合嵌入预测学习视觉语义特征，SAVi[50] 和 Slot-Former[51] 探索对象级表示及其时间演化；DINO-WM[52] 利用预训练视觉特征进行

动作条件预测与规划，V-JEPA 2[53] 进一步结合视频表征学习与机器人交互数据开展预测和规划研究。FR3D[54]、Flow Equivariant World Models[55] 和多视角掩蔽世界模型 [56] 则分别从三维潜在表征、运动等变记忆和多视角观测扩展世界建模能力。这类方法能够利用视觉先验学习具有预测价值的状态，但特征空间中的变化是否准确对应真实几何、运动及物理关系，仍需进一步验证。

生成式世界模拟模型以未来图像、视频或可交互环境为预测对象，利用生成模型模拟环境演化。Genie[57] 从无标注视频学习潜在动作与交互环境，GameNGen[58] 探索基于扩散模型的实时游戏模拟，Genie 2[59] 进一步研究可交互的三维环境生成。DriveDreamer[60]、DriveDreamer-2[61] 和 Epona[62] 面向自动驾驶场景开展条件视频生成与环境预测；Cosmos[6] 提供面向物理智能的世界基础模型平台，Genie 3[5]、Genie 4[63] 和 Infinite-World[64] 则进一步探索实时交互生成与长序列空间一致性。这类方法推动了世界模拟的生成能力与交互能力，但视觉生成质量并不必然对应准确的三维运动、物理结构及动作响应，长期状态一致性和物理约束仍是重要研究问题。

三维结构与物理世界模型通过显式或结构化的空间状态描述环境，并在此基础上学习动态演化。Graph Network-based Simulators（GNS）[65] 利用粒子交互学习物理动力学，OccWorld[66] 和 GenieDrive[67] 将三维或四维占据表示用于自动驾驶环境预测。PhysTwin[12] 从视频中恢复可变形对象及物理参数，GWM[68] 将三维高斯表示与生成式动态模型相结合，PointWorld[11] 则利用三维点流开展动作条件预测与规划。进一步地，PERSIST[69] 通过持久三维状态维护空间信息，VectorWorld[70] 利用结构化向量图进行流式世界建模与演化预测。这些研究表明，三维几何、运动及物理关系正逐渐成为世界模型内部状态的重要组成部分。但不同方法的观测条件、状态组织、历史利用方式及预测目标仍存在差异，连续运动历史与当前有效结构如何共同支持状态维护和动作响应预测，仍值得深入研究。

总体来看，世界模型已形成从潜在动力学、视觉特征预测到生成式模拟和结构化三维预测的多种技术路线。潜在模型强调紧凑状态与任务相关性，视觉模型利用预训练表征，生成模型关注环境演化的视觉模拟，三维模型则为几何、运动及物理关系提供更明确的表示基础。近年来，相关研究逐渐重视持续状态维护及其与未来预测的联系，但对于观测不完整、运动与结构持续变化的真实三维环境，如何构建可持续修正的内部状态，以及连续运动、对象归属、物理连接和交互历史等信息对动作后果预测的实际作用，仍有待进一步研究。

1.2.3 具身操作中的动作学习

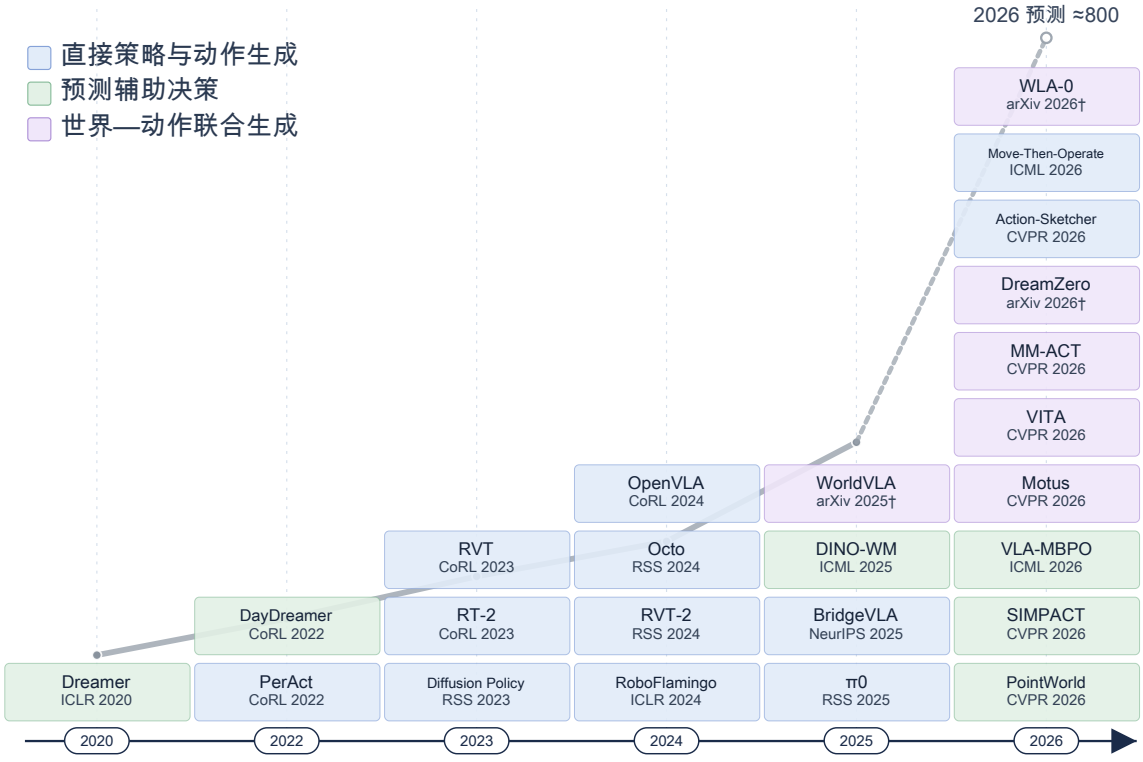


图 5 具身操作动作学习的代表性工作与发展脉络（† 表示预印本）

具身操作中的动作学习旨在根据视觉观测、机器人状态及任务要求生成动作，是连接环境感知与智能体交互的重要环节。随着视觉语言模型、三维感知和生成式模型的发展，相关研究逐渐从直接动作预测扩展到利用环境预测辅助决策，以及世界状态与动作的联合建模 [71]。图 5 汇总了 2020—2026 年的代表性工作，主要包括直接策略与动作生成、预测辅助决策和世界—动作联合生成三类技术路线。

直接策略与动作生成侧重从视觉观测、语言指令及机器人状态直接学习动作映射。RT-2 和 OpenVLA 将视觉语言模型扩展到机器人动作生成 [72-73]，Diffusion Policy 和 π_0 分别利用扩散模型与流匹配方法建模连续动作 [74-75]。RoboFlamingo、PerAct、RVT-2 和 BridgeVLA 则通过时序建模、体素表示、多视角几何或三维输入输出对齐增强空间感知与操作能力 [76-79]。这类方法推动了跨任务动作学习，但其主要目标是建立观测到动作的映射，并不必然要求显式恢复连续运动、对象关联及物理结构等内部状态。

预测辅助决策通过预测未来环境或任务状态，为动作选择、优化与规划提供依据。Dreamer 在潜在空间中生成想象轨迹并学习控制策略 [44]，DINO-WM 利用预训练视觉特征预测动作条件下的未来变化，并通过模型预测优化动作序列 [52]；PointWorld 则以三维点流预测场景运动，为模型预测控制提供支持 [11]。不同方法利用潜在状态、视觉特征或显式三维结构描述未来，其预测信息的形式和作用有所不同。如何使内部状态充分保留影响动作响应的动态信息，以及预测精度能否转化为实际任务收益，仍需结合具体交互条件进行检验。

世界—动作联合生成进一步将环境演化预测与动作生成纳入统一模型。World-VLA 通过自回归建模联合预测未来图像与机器人动作 [80]，DreamZero 则利用视频生成模型联合学习未来视觉变化和动作，探索世界动态知识对操作策略的支持 [81]。这类方法加强了环境预测与动作学习之间的联系，但未来视觉生成与动作输出的一致性，并不必然保证真实物理响应的准确性，仍需结合执行反馈和物理状态评价加以验证。

具身操作研究依赖具有视觉观测、动作记录及任务评价条件的数据和实验平台。BridgeData V2 和 DROID 提供真实机器人操作数据 [82-83]，RLBench、LIBERO 和 CALVIN 支持多任务与长程操作评价 [84-86]，RoboCasa、RoboTwin 和 SIMPLER 则提供不同场景和条件下的仿真验证环境 [87-89]。由于数据集在相机配置、动作空间、控制频率及任务判据上存在差异，相关比较需要明确观测条件与评价协议。

总体来看，具身操作研究正逐渐融合视觉语义、三维空间信息、动作生成与环境预测。直接策略学习侧重动作映射，预测辅助决策利用未来状态评价动作，联合生成模型则探索世界演化与动作之间的相互促进。对于连续动态世界模型而言，具身交互不仅提供动作条件和应用场景，也为检验动态状态的预测价值提供了依据：连续运动、对象归属及物理连接等信息能否改善动作后果预测，以及这种改善能否进一步支持实际交互，仍需要在一致的观测与动作条件下加以验证。

1.2.4 总结

综上，四维动态场景重建、世界模型和具身操作中的动作学习，分别从动态三维状态恢复、内部状态演化预测及动作条件交互等方面提供了研究基础。四维重建已能够恢复复杂几何与连续运动，并探索对象关联和结构更新；世界模型将潜在状态、视觉特征或三维结构用于未来演化预测；具身操作则进一步将环境预测与动作生成、规划及交互验证相联系。三个领域逐渐交叉融合，但动态场景的几何与运动恢复、世界状态的持续维护及动作条件预测具有不同的研究目标，重建质量或交互性能并不能直接说明内部状态的完整性及其预测价值。

面向有限视觉观测下的复杂动态环境，仍有两个相互关联的问题值得深入研究：一是离散采样、遮挡及物理连接变化可能使不同运动与结构状态产生相近的观测结果，需要研究**连续运动与场景结构的可区分条件**，以及如何在观测不完备时维护状态一致性、更新失效约束并保留有效历史；二是连续运动、对象归属和物理连接等状态信息对未来动作响应的作用尚需明确，需要研究**不同状态信息的预测价值及其估计误差对动作后果的影响**。围绕上述问题，本课题拟研究连续动态场景表征的构建与持续维护，并进一步探索其与动作条件演化预测的协同关系。

1.3 已有工作积累及研究基础

1.3.1 连续时间重建的前期探索

前期工作 CoFuse4D 的论文题目为 *CoFuse4D: Dense Correspondence Fusion for Dynamic Gaussian Splatting*。该工作研究如何从单目动态视频中把大量带噪的稠密二维对应融合为少量连续时间运动节点的估计，并以对象身份约束跨帧关联。其核心思

想是：运动自由度应少于观测数量，但观测证据应尽量保留；连续时间表达使运动可在任意时刻查询，身份约束则避免不同物体在同一运动场中相互污染。

方法框架如图 6 所示。CoFuse4D 用连续时间高斯过程表示少量运动节点的位置与旋转，以轨迹级对象身份约束跨帧关联和邻域混合，再把同一关联传递给高斯变形与渲染，使运动估计与高斯重建共享同一套对应关系，并通过二维重投影、光度与几何监督联合优化。这一约束链条对应本课题关注的观测不确定性、连续运动与空间组织：观测置信度影响运动估计，运动连续性约束几何累积，身份一致性限制跨对象信息共享。

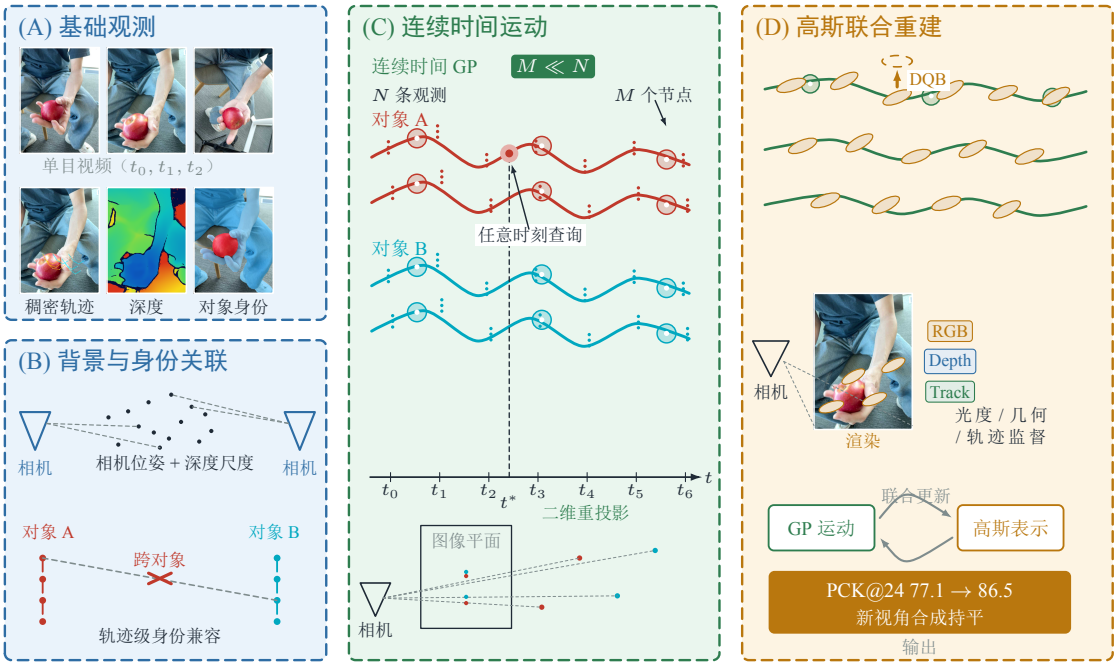


图 6 CoFuse4D 的方法框架

在 DyCheck 七个场景上，七场景等权平均的高斯渲染轨迹在 24 像素阈值下的命中率（PCK@24）由 77.15% 提升至 86.54%，新视角合成性能与冻结原始运动的参照重建基本持平。这说明连续时间运动表达与稠密对应融合已经可行，为本课题第一项研究提供了多时刻证据利用、置信度加权和连续查询的基础，也为第二项研究提供了运动状态与身份约束的组织经验；对象边界、表面归属及观测不确定性仍需在后续研究中处理。该工作已基本完成、尚未发表，计划投稿至 CVPR 2027。

1.3.2 动作条件状态学习的前期探索

前期工作 PS-VLA 的论文题目为 *PS-VLA: Learning Action-Conditioned Predictive States for Robotic Manipulation*。该工作在 BridgeVLA 的视觉-语言-动作框架 [79] 上，研究机器人在连续执行中如何维护可预测、可修正的任务状态。BridgeVLA 主要依据当前多视角观测直接生成动作；当视觉观测存在较大不确定性或动作未产生预期效果时，仅依赖当前观测难以为后续决策保留一致的历史。PS-VLA 因此引入持续潜在状

态：先根据上一时刻的后验、上一动作及实际执行反馈预测当前先验，再利用当前视觉 token 进行观测更新，得到后验状态。方法框架如图 7 所示。

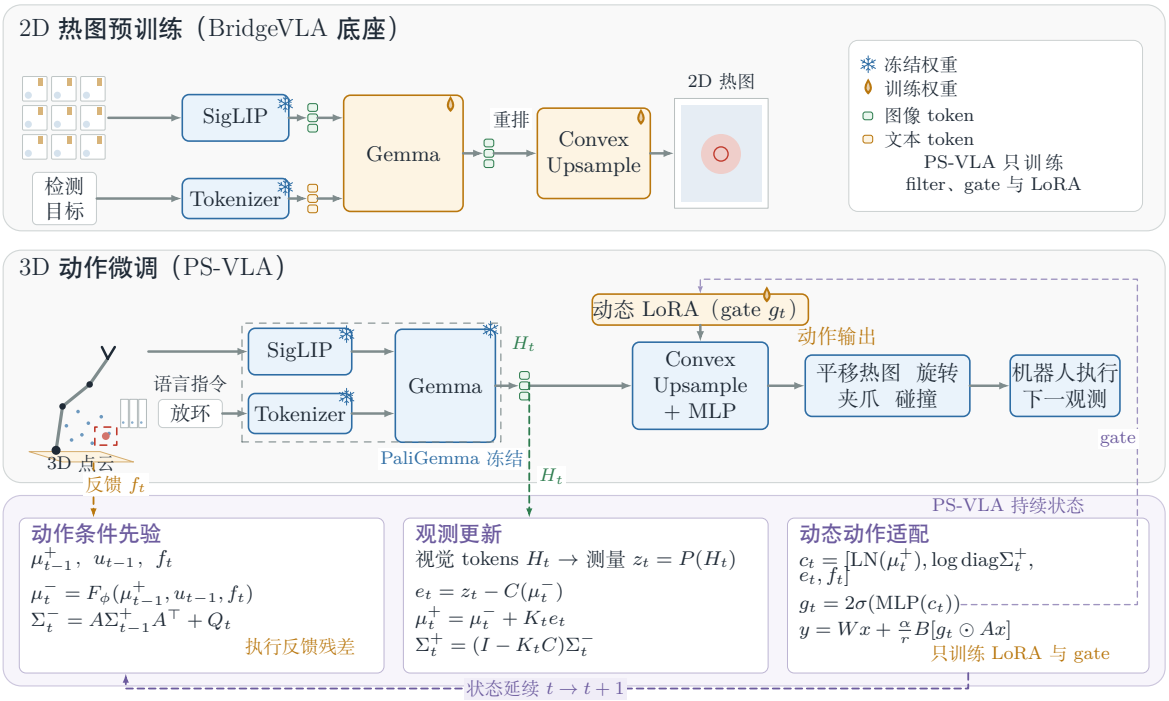


图 7 PS-VLA 的方法框架

这一设计的核心是让状态在观测到来前先给出预测，再由新证据修正，而不是对当前帧重新编码或对历史无条件延续；实际执行反馈用于判断偏离来自观测噪声还是动作未按预期执行，使状态更新不必在“相信历史”和“相信当前观测”之间做固定选择。后验状态进一步通过动态 LoRA 的门控进入平移热图、旋转、夹爪和碰撞等动作头，使状态估计与动作适配共享同一更新链条。该工作为本课题第四项研究提供了状态转移、观测修正和动作条件适配的实现经验，也说明动作后果预测需要同时利用历史状态和当前证据。该工作已基本完成、尚未发表，计划投稿至 CVPR 2027。

二、学位论文研究内容

学位论文的研究目标、研究内容及拟解决的关键性问题（可续页）

2.1 研究目标

本课题面向有限时序视觉观测下的三维动态场景，针对离散采样导致的连续运动约束不足、不完整观测下的对象归属歧义、物理连接变化后的结构约束失效，以及场景表征与动作后果预测衔接不足等问题，研究连续动态世界模型的构建方法。**总体目标是建立能够持续维护场景状态、适应局部结构变化，并在给定动作条件下预测未来几何与运动变化的连续动态世界模型**，为复杂动态环境中的预测与决策提供方法基础。研究按照“状态恢复—结构组织—变化适应—演化预测”逐步展开：首先恢复非采样时刻的连续运动与几何，建立可随观测修正的动态表征；其次利用连续运动组织对象与部件的时空关系，维持空间归属一致性；进一步针对物理连接变化更新局部结构并保留有效历史；最后结合观测与交互历史，研究动态状态与动作条件演化预测的协同建模。

2.2 研究内容

围绕上述目标，本课题设置四项相互关联的研究内容，共同研究有限观测中的连续运动与结构信息如何形成可用于动作后果预测的世界模型内部状态。前三项分别处理离散采样下的运动歧义、不完整观测下的对象归属歧义，以及物理连接改变后的结构约束失效，建立能够持续修正的连续动态场景表征；第四项进一步结合交互历史补充预测相关状态，并通过动作条件演化预测检验和完善内部表征。四项研究既可以分别开展机制验证，又通过统一的世界状态相互衔接，研究组织关系如图 8 所示。



图 8 连续动态世界模型研究框架

（1）研究内容一：不确定性感知的连续时间场景表征

有限离散观测只直接约束部分时刻与可见区域，采样间隙、快速运动与遮挡相互叠加时，多种运动解释可能同时符合观测；不同区域、不同时刻的观测支持及估计不确定性也不相同，时间表达能力需要与有效观测支持和运动复杂性相匹配：表达自由度超出观测支持时，帧间运动可能缺乏充分约束；表达能力不足时，则难以刻画真实运动变化。本项研究的问题是：如何在非采样时刻恢复连续运动与几何，刻画其不确定性，并使表征随新观测修正。拟依据跨时刻对应、可用几何及可见性的一致程度确定证据的作用范围，使运动描述及其约束强度与有效观测支持相适应，在证据不足处保留不确定性，在证据充分处刻画与观测相容的运动变化；并研究连续运动与多时刻几何的相互校正，使运动估计和几何累积互为约束。预期形成可连续查询、可随观测修正的动态场景表征，描述非采样时刻运动与几何的估计及其不确定性，并为对象时空关联和动作预测提供时间基础。

（2）研究内容二：连续运动引导的对象时空一致性建模

遮挡、短时共动及已有表面首次显露会使跨时刻关联出现歧义：不同对象的场景单元可能因邻近、共同运动或短暂接触而被错误关联，同一对象在遮挡或形变后又可能失去稳定对应；遮挡解除后首次显露的已有表面则缺少直接的历史观测。单帧几何难以区分这些情形，错误关联还可能使局部误差传播到其他区域。本项研究的问题是：在物理连接未发生改变的条件下，如何依据有限观测维护对象时空一致性，确定对象或部件归属并限定信息共享范围。拟以连续运动为主要线索，结合几何、外观与可见性建立可随证据修正的空间关联，将首次显露的已有表面作为已有结构的信息补充纳入一致的空间组织；进一步研究空间归属对信息共享范围的约束及其对连续运动恢复和几何累积的作用，使运动估计与对象组织相互校正。预期形成对象归属相对稳定、局部信息可持续完善的动态表征，为后续结构更新和动作影响范围判断提供依据。

（3）研究内容三：物理连接变化下的动态结构表征与更新

切割、撕裂等物理连接改变会使原有邻接和共享运动约束局部失效，继续沿用会错误绑定已经分离的区域，整体重置又会丢失未受影响区域中有观测支持的信息；新生边界在形成之前也没有可对应的表面历史。本项研究的问题是：结构事件前后如何协调几何、运动与物理连接状态，在保留稳定区域有效历史的同时更新变化后的动态结构。拟结合时序运动、局部几何及边界变化等观测证据，判断物理连接的保持、失效与待定状态，对具有充分证据的结构变化解除失效约束并更新局部几何，区分新生物理边界与已有表面的首次显露；表示单元新增及历史对应缺失仅作为辅助信息。预期形成能够维护有效物理连接、适应局部结构变化并延续稳定区域历史的动态表征，为动作后果预测提供符合当前物理状态的结构依据。

（4）研究内容四：动作后果预测与连续动态表征协同建模

动作响应受已有运动趋势、对象归属、物理连接及未充分观测的动力学因素共同影响，相近的瞬时几何可能对应不同的动作后果。前三项形成的连续动态场景表征为预测提供几何、运动和结构基础，但不一定充分包含质量、摩擦、刚度等响应相关因素，且这些因素未必能仅凭有限视觉观测唯一辨识。本项研究的问题是：如何利用截

至预测起点的观测与交互历史补充预测相关状态，并使状态表达与给定动作下的演化预测相互约束。拟将连续运动和有效结构作为可解释的基础状态，结合交互历史学习响应相关的潜在状态；在给定动作条件下预测后续几何与运动变化，通过预测误差和机制消融分析不同状态信息的实际贡献，研究状态估计误差向动作响应误差的传递。预测起点之后的真实观测仅用于训练监督、效果评价和后续状态修正，不作为该次预测输入。预期形成持续动态状态与动作条件演化协同建模的方法，并在公开交互序列中检验其预测价值与适用条件。

2.3 拟解决的关键科学问题

本课题以截至预测起点的有限视觉观测与交互历史为依据，研究连续动态场景状态的构建及其在给定动作下的演化预测。关键科学问题聚焦两个相互关联的方面：一是有限观测下连续运动与场景结构的可区分条件，二是动态状态信息对动作响应预测的作用及误差传递机理。前三项研究主要围绕动态状态的恢复与持续维护展开，第四项进一步研究状态表征与动作条件预测之间的关系；物理连接变化既影响观测解释，也影响动作响应，是两个问题的重要联系。

（1）不完备观测下连续运动与场景结构的可区分条件

有限离散观测中，不同连续运动轨迹、对象归属及物理连接关系可能产生相近的可见结果，时间连续性与空间结构先验能够排除部分解释，也可能在证据不足时引入错误约束。运动与结构状态的可区分性受到观测条件、运动差异及先验约束的共同影响。本课题拟在限定的相机配置、观测噪声、时间窗口和场景条件下，研究时间采样、可见范围、相对运动及几何约束对状态可区分性的影响，分析连续运动与空间归属提供互补证据的条件，以及物理连接变化前后原有约束和历史信息的有效范围。重点揭示限定观测条件下的状态可区分关系与恢复边界，明确不可消除的观测歧义及需要保留的不确定性，为连续动态场景状态的可靠估计与持续维护提供依据。

（2）动作响应预测的状态表征需求与误差传递机理

与已有观测相容的不同运动和结构状态，在给定动作下可能产生不同的未来响应，也可能在一定预测范围内表现近似。因此，动态场景的重建精度与动作响应预测能力并不必然一致，状态信息的预测价值取决于其对未来动作响应的区分作用。本课题拟研究连续运动历史、对象归属、物理连接及响应相关状态对未来几何与运动预测的作用，分析不同状态信息的独立贡献、相互依赖及可替代条件；进一步研究运动估计偏差、空间归属错误与连接状态不确定性对预测结果及响应传播范围的影响，区分状态信息本身的作用与模型参数化、容量等实现因素带来的收益。通过分析状态信息、预测误差与动作条件之间的关系，揭示状态估计误差向动作响应误差传递的条件与规律，明确连续动态表征的预测需求及其适用边界。

三、学位论文研究计划及预期目标

1. 拟采取的主要理论、研究方法、技术路线和实施方案（可续页）

3.1 主要理论

3.1.1 三维场景表示与高斯泼溅

三维场景表示旨在通过一定的数据结构或数学模型描述真实环境的空间几何与外观属性，是三维重建、场景理解及新视角合成的基础。常见的三维表示包括点云、三角网格、隐式神经场和显式几何图元等。点云通过离散空间采样描述物体形状，三角网格利用顶点与面片表达连续表面，隐式场通过连续函数表示空间密度或表面距离，显式图元则利用具有位置、尺度及外观属性的基本单元构建场景。不同表示形式在几何表达能力、存储开销及渲染效率方面具有不同特点。

三维高斯泼溅（3D Gaussian Splatting，3DGS）是一种基于显式高斯图元的三维场景表示与可微渲染方法 [22]。该方法使用一组三维各向异性高斯描述场景，每个高斯图元包含中心位置、协方差、不透明度及颜色等属性。其中，三维高斯的空间分布可表示为

$$G_i(\mathbf{x}) = \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_i)^\top \boldsymbol{\Sigma}_i^{-1}(\mathbf{x}-\boldsymbol{\mu}_i)\right), \tag{1}$$

其中，$\mathbf{x} \in \mathbb{R}^3$ 为空间位置，$\boldsymbol{\mu}_i \in \mathbb{R}^3$ 为第 i 个高斯的中心，$\boldsymbol{\Sigma}_i \in \mathbb{R}^{3\times3}$ 为其协方差矩阵。协方差通常通过旋转矩阵与尺度参数构造，以保证其对称正定性，并描述高斯图元在不同空间方向上的形状和范围。

在渲染过程中，三维高斯经过相机投影形成图像平面上的二维高斯分布，并根据深度顺序进行颜色与透明度合成。对于给定像素，其颜色可以表示为

$$\mathbf{C} = \sum_{i=1}^{N} \mathbf{c}_i \alpha_i \prod_{j=1}^{i-1}(1-\alpha_j), \tag{2}$$

其中，N 为参与该像素合成的高斯数量，$\mathbf{c}_i$ 为对应高斯的颜色，α_i 为由不透明度及投影高斯分布共同确定的像素贡献权重。通过可微渲染，可以利用图像重建误差对高斯图元的几何及外观参数进行优化。三维高斯表示兼具显式空间参数与高效渲染能力，为三维场景的可视化、重建及后续动态扩展提供了基础。

3.1.2 动态场景表示与连续时间运动

与静态场景不同，动态场景中的物体位置、几何形状及外观可能随时间发生变化，因此需要在三维空间表示中进一步引入时间维度。动态场景表示通常需要描述场景在不同时刻的状态及其相互联系。常见方式包括直接建立时变几何表示，以及通过运动或形变映射描述场景单元随时间的变化。后者通过建立参考状态与不同时刻之间的空间映射，使几何信息能够在时间维度上建立联系 [18-20, 23-24]。

运动可以采用离散时间或连续时间形式进行描述。离散时间表示记录一系列采样时刻的空间状态，连续时间表示则利用以时间为自变量的函数描述运动过程。对于参

考位置为 $\mathbf{x}_0$ 的场景点，设其运动映射 $\Phi(\mathbf{x}_0, t)$ 关于时间 t 可微，则该点在时刻 t 的位置及瞬时速度可写为

$$\mathbf{x}(t) = \Phi(\mathbf{x}_0, t), \qquad \mathbf{v}(t) = \frac{\partial \Phi(\mathbf{x}_0, t)}{\partial t}, \tag{3}$$

其中，Φ 表示随时间变化的空间映射，$\mathbf{v}(t)$ 为位置对时间的一阶导数。连续时间表示允许在函数定义域内查询非采样时刻的运动状态，常见参数化形式包括多项式、样条函数及神经网络等。其实际恢复精度仍取决于观测条件、函数表达能力及所采用的运动假设。

根据场景的运动性质，可以进一步区分刚体运动与非刚性形变。刚体运动保持物体内部任意两点之间的距离不变，通常由旋转和平移描述，其空间变换属于特殊欧氏群 $\mathrm{SE}(3)$。对于参考位置 $\mathbf{x}_0$，刚体运动可表示为

$$\mathbf{x}(t) = \mathbf{R}(t)\mathbf{x}_0 + \mathbf{p}(t), \qquad \mathbf{R}(t) \in \mathrm{SO}(3),$$

其中，$\mathbf{R}(t)$ 和 $\mathbf{p}(t)$ 分别表示旋转矩阵与平移向量。刚体变换满足任意两点之间的距离保持关系：

$$\|\mathbf{x}_i(t) - \mathbf{x}_j(t)\|_2 = \|\mathbf{x}_{i,0} - \mathbf{x}_{j,0}\|_2.$$

非刚性形变则允许物体内部的相对位置发生变化，需要更一般的空间映射进行描述。在实际动态场景中，不同区域可能具有不同的运动形式，局部运动也可能仅在特定时间区间内满足相应的连续性或刚性假设。

3.1.3 空间结构与拓扑关系

三维场景不仅包含几何元素及其运动状态，还具有由对象、部件及其相互关系构成的空间组织结构。从不同抽象层次出发，场景可以表示为基本几何单元的集合，也可以进一步组织为具有独立身份的对象及其内部部件。对象级表示侧重区分不同实体，部件级表示则描述对象内部具有一定几何或运动联系的组成部分。层次化空间组织能够在不同粒度上描述场景结构及其关系。

空间关系可以根据几何、运动或物理属性进行定义，例如空间邻近、包含、接触、共同运动及物理连接等。图结构是描述元素及其关系的一种常见数学形式，可表示为

$$\mathcal{H} = (\mathcal{V}, \mathcal{E}), \qquad \mathcal{E} = \bigcup_{r \in \mathcal{R}} \mathcal{E}^{(r)},$$

其中，$\mathcal{V}$ 为节点集合，$\mathcal{E}$ 为关系集合，$\mathcal{R}$ 表示关系类型集合，$\mathcal{E}^{(r)}$ 表示第 r 类关系对应的边集合。节点可以对应空间点、几何单元、部件或对象，不同类型的边则用于描述几何邻近、运动关联或物理连接等关系。几何邻近、运动相似与物理连接属于不同性质的关系：空间相邻的元素不一定具有物理连接，共同运动的元素也不一定属于同一对象。

拓扑结构主要描述空间对象的连通性等性质，以及这些性质在连续形变下的保持关系。对于拓扑性质不发生变化的物体，连续且具有连续逆映射的形变可以改变其几

何形状而不改变拓扑类型；切割、撕裂等过程则可能改变原有连通关系，并产生新的物理边界。需要注意，关系图中边的变化不一定意味着真实物理拓扑改变，例如基于距离或运动相似性建立的关联可能随状态变化而更新。与此同时，遮挡解除导致已有表面首次进入视野，仅属于观测可见性的变化，并不意味着物体本身发生了拓扑改变。因此，在动态场景描述中，几何变化、关系变化、可见性变化与物理拓扑变化具有不同的概念和建模含义。

3.1.4 状态空间模型与动态演化

状态空间模型（State-Space Model）是描述动态系统内部状态及其演化规律的经典数学框架。该模型通常通过状态转移关系描述系统随时间的变化，并通过观测关系建立内部状态与外部测量之间的联系。在离散时间条件下，一般状态空间模型可以写为

$$\begin{aligned} \mathbf{s}_{k+1} &= F(\mathbf{s}_k, \mathbf{a}_k, \boldsymbol{\epsilon}_k), \\ \mathbf{o}_k &= H(\mathbf{s}_k, \boldsymbol{\eta}_k), \end{aligned} \tag{4}$$

其中，$\mathbf{s}_k$ 为时刻 k 的系统状态，$\mathbf{a}_k$ 为外部动作或控制输入，$\mathbf{o}_k$ 为观测结果，$\boldsymbol{\epsilon}_k$ 和 $\boldsymbol{\eta}_k$ 分别表示过程噪声与观测噪声。状态转移函数 F 描述当前状态与动作共同决定的后续演化，观测函数 H 描述系统状态产生可观测信息的过程。对于连续时间系统，也可以利用微分方程描述状态变化率及其与外部输入的关系。

在部分可观测条件下，系统的真实内部状态通常无法直接获取，需要根据已有观测与动作历史进行估计。部分可观测马尔可夫决策过程（Partially Observable Markov Decision Process，POMDP）为此提供了经典理论框架 [90]。在状态满足马尔可夫假设时，贝叶斯滤波通过状态预测和观测更新两个步骤递推估计状态分布，其基本关系为

$$\begin{aligned} \bar{b}_{k+1}(\mathbf{s}) &= \int p(\mathbf{s} \mid \mathbf{s}', \mathbf{a}_k)\, b_k(\mathbf{s}')\, d\mathbf{s}', \\ b_{k+1}(\mathbf{s}) &\propto p(\mathbf{o}_{k+1} \mid \mathbf{s})\, \bar{b}_{k+1}(\mathbf{s}), \end{aligned} \tag{5}$$

其中，b_k 表示根据已有信息形成的状态信念分布，$\bar{b}_{k+1}$ 表示动作条件下的预测分布，b_{k+1} 表示结合新观测更新后的状态分布。上述过程体现了动态系统中状态演化与观测修正的基本关系。

世界模型将状态表示与环境演化预测相结合，通过学习状态转移规律，对给定条件下的未来状态或观测进行预测。学习式世界模型可以在显式物理状态、视觉特征或潜在状态空间中建立动态关系，并根据任务需要支持环境预测、过程推演及决策 [1, 43-44, 2]。不同模型的状态表达形式与预测目标可能不同，但均涉及如何利用已有信息描述当前环境，以及如何根据状态和外部条件刻画后续变化的基本问题。

3.2 研究方法

本课题拟采用理论分析、算法设计与实验验证相结合的研究方法。首先，围绕有限视觉观测下动态状态的可区分性及动作响应预测的状态需求，分析连续运动、空间结构与动态演化的基本关系，明确相关问题的建模条件与研究边界；其次，结合计算机视觉、三维重建及机器学习等技术，开展连续时间场景表征、对象时空一致性建模、

物理连接变化适应和动作后果预测等方面的算法研究；最后，依托公开数据集与实验平台，通过基线对比、受控实验、消融分析及误差分析，验证所提出方法的有效性，研究关键因素的作用及方法的适用条件。

3.3 技术路线

本课题围绕连续动态世界模型的构建，以有限时序视觉观测及可用几何先验为基础，通过连续时间运动恢复、对象时空一致性建模和物理连接变化适应，协同建立可持续维护的动态场景状态。在此基础上，结合交互历史引入响应相关状态，以动作条件演化预测为目标进一步完善内部世界表征，形成状态构建、演化预测与观测修正相联系的模型框架。总体技术路线如图 9 所示。

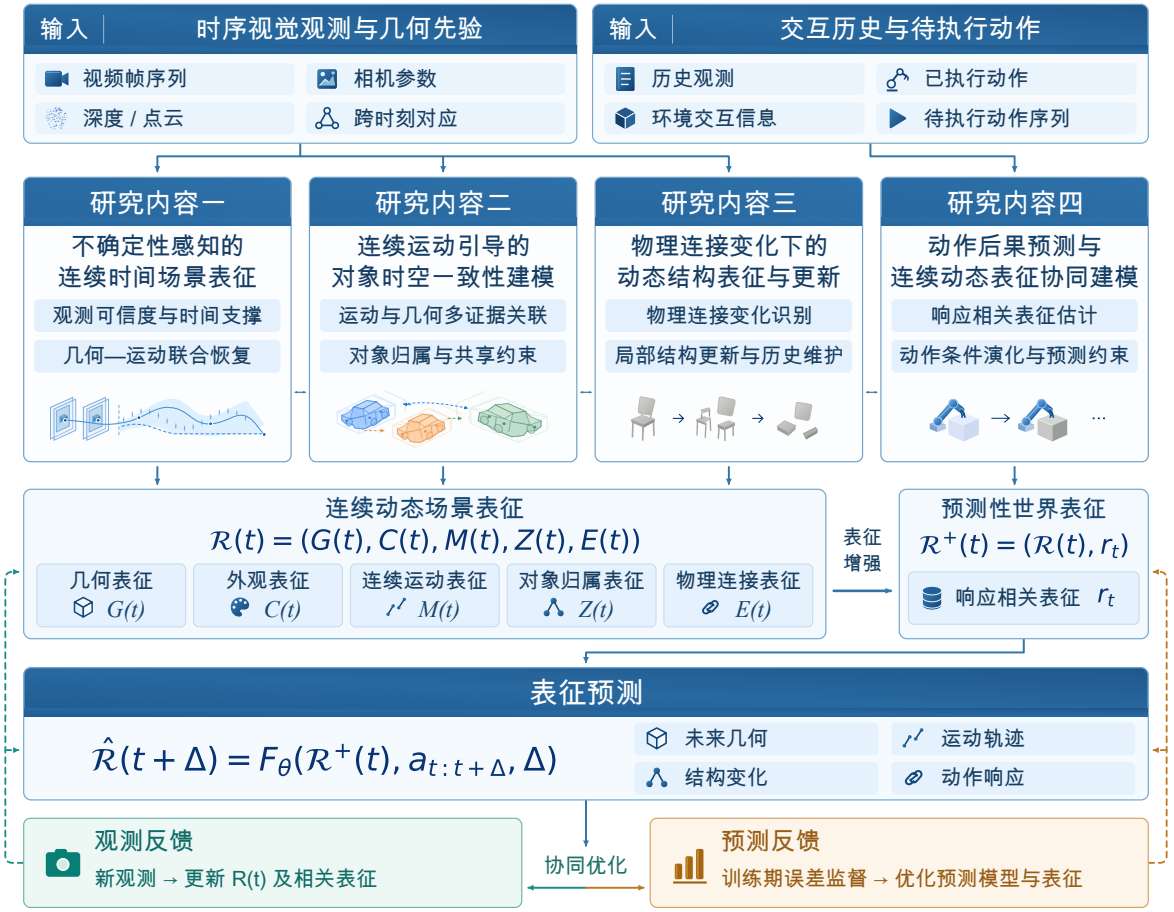


图 9 连续动态场景表征与动作条件预测技术路线

为统一描述动态场景的几何、外观、运动及结构关系，本课题构建可按时间查询、可随观测更新的动态场景表征：

$$\mathcal{R}(t) = \big(\mathcal{G}(t), \mathcal{C}(t), \mathcal{M}(t), \mathcal{Z}(t), \mathcal{E}(t)\big), \tag{6}$$

其中，$\mathcal{G}(t)$ 和 $\mathcal{C}(t)$ 分别表示场景的三维几何与外观表征，$\mathcal{M}(t)$ 表示连续运动表征，$\mathcal{Z}(t)$ 表示对象或部件的空间归属，$\mathcal{E}(t)$ 表示物理连接及拓扑关系。场景状态可在连续时间轴上查询，其中结构关系允许随物理事件发生离散变化。前三项研究围绕上述分量的连续恢复、空间组织与结构更新展开，协同构建时空一致的动态场景表征。

在此基础上，第四项研究结合截至预测起点 t_0 的观测与交互历史，估计响应相关的潜在状态 r_{t_0}，将基础动态表征增强为预测性世界表征：

$$\mathcal{R}^{+}(t_0) = \big(\mathcal{R}(t_0), r_{t_0}\big), \tag{7}$$

并在给定动作条件下预测未来几何与运动响应，研究对象归属及物理连接对响应传播的影响，利用预测任务进一步约束和优化内部表征。预测起点之后的真实观测仅用于训练监督、效果评价及后续表征修正，不作为该次预测输入。四项研究的具体技术路线分别如下。

3.3.1 不确定性感知的连续时间场景表征



图 10 不确定性感知的连续时间场景表征技术路线

本项研究面向有限离散视觉观测下的连续运动与动态几何恢复，采用“可靠观测证据构建—观测驱动的连续运动建模—几何与运动联合恢复”的技术路线，如图 10 所示。首先融合视觉基础模型提供的几何与跨时刻对应先验，构建具有可靠性和时间覆盖信息的观测约束；随后以稀疏运动支撑建立连续时间变形模型，根据观测支持自适应调整局部运动表达能力；最后结合三维高斯表示与多时刻联合优化，持续校正动态场景的几何和运动，并维护弱观测区域的运动不确定性。

（1）可靠观测证据构建

设输入视频序列为 $\mathcal{I} = \{I_k\}_{k=1}^{N}$，对应采样时刻为 $\{t_k\}_{k=1}^{N}$。利用视觉基础模型获取相机参数、深度图及跨时刻二维对应，并通过深度反投影与坐标统一获得初始三维轨迹。对于轨迹 a 在时刻 t_k 的观测，综合对应一致性、几何一致性及可见性，构建可靠性权重 $w_{a,k} = c_{a,k}^{\text{track}} c_{a,k}^{\text{geo}} v_{a,k}$，以调节不同观测在后续运动恢复中的作用。

考虑动态场景各区域的时间采样和有效观测覆盖不同，进一步根据初步轨迹及候选运动支撑区域统计局部时间证据：

$$H_j(t) = \sum_{a,k} \beta_{a,j} w_{a,k} \kappa_h(t - t_k), \tag{8}$$

其中，$\beta_{a,j}$ 为轨迹 a 对候选支撑区域 j 的关联权重，κ_h 为局部时间核函数，$H_j(t)$ 表示该区域在时刻 t 附近的有效观测支持。通过联合考虑观测可靠性和时间覆盖，建立加权时空约束，为后续连续运动建模提供可靠证据及局部约束强度依据。

（2）观测驱动的连续运动建模

根据三维轨迹的空间分布和运动一致性初始化稀疏运动支撑节点，以少量连续轨迹描述局部场景运动。设节点 j 的参考位置为 $\mathbf{p}_j^0$，参考时刻为 t_{ref}，采用样条基函数建立连续时间位置轨迹：

$$\mathbf{p}_j(t) = \mathbf{p}_j^0 + \sum_{\ell=1}^{L_j} \big[B_{j,\ell}(t) - B_{j,\ell}(t_{\text{ref}})\big] \mathbf{c}_{j,\ell}, \tag{9}$$

其中，$B_{j,\ell}(t)$ 为时间基函数，$\mathbf{c}_{j,\ell}$ 为控制参数，L_j 为局部时间控制参数数量。节点旋转 $\mathbf{R}_j(t) \in \mathrm{SO}(3)$ 采用连续旋转参数化描述，并满足参考时刻的旋转为单位矩阵。

对于参考状态下的三维位置 $\mathbf{x}$，由邻近运动节点的局部变换构建连续变形映射：

$$\Phi(\mathbf{x}, t) = \sum_{j \in \mathcal{N}(\mathbf{x})} \alpha_j(\mathbf{x}) \left[\mathbf{R}_j(t)(\mathbf{x} - \mathbf{p}_j^0) + \mathbf{p}_j(t)\right], \tag{10}$$

其中，$\mathcal{N}(\mathbf{x})$ 为局部运动支撑集合，$\alpha_j(\mathbf{x})$ 为归一化的非负关联权重。该映射将稀疏运动轨迹传播至三维高斯图元，实现稠密动态几何的连续时间表达。

针对不同区域运动复杂度和观测支持的差异，拟结合时间覆盖与运动拟合残差，自适应调整局部样条控制点数量，并构建观测支持驱动的运动正则约束：

$$\begin{aligned} \mathcal{L}_{\text{motion}} &= \sum_j \int_{\mathcal{T}} \lambda_j(t) \left\| \frac{\partial^2 \mathbf{p}_j(t)}{\partial t^2} \right\|_2^2 \mathrm{d}t, \\ \lambda_j(t) &= \lambda_{\min} + \frac{\lambda_0}{H_j(t) + \epsilon}, \end{aligned} \tag{11}$$

其中，$\lambda_j(t)$ 为局部运动平滑权重，$\mathcal{T}$ 为建模时间范围，$\lambda_{\min}$、λ_0 为调节参数。通过运动表达复杂度与平滑强度的协同调整，使观测充分的区域能够刻画复杂运动变化，同时提高稀疏观测区域的轨迹估计稳定性。

（3）几何—运动联合恢复

在连续运动模型的基础上，采用三维高斯表示动态场景的几何与外观，通过连续变形更新图元状态，并利用可微渲染建立跨时刻观测约束。设几何、外观和运动参数分别为 Θ_G、Θ_C 和 Θ_M，构建联合优化目标：

$$\begin{aligned} \min_{\Theta_G, \Theta_C, \Theta_M} \quad & \mathcal{L} = \lambda_{\text{trk}} \mathcal{L}_{\text{trk}} + \lambda_{\text{rgb}} \mathcal{L}_{\text{rgb}} \\ & + \lambda_{\text{dep}} \mathcal{L}_{\text{dep}} + \lambda_{\text{mot}} \mathcal{L}_{\text{motion}} + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}}, \end{aligned} \tag{12}$$

其中，$\mathcal{L}_{\text{trk}}$ 为观测可靠性加权的轨迹重投影损失，$\mathcal{L}_{\text{rgb}}$ 和 $\mathcal{L}_{\text{dep}}$ 分别为图像重建与深度一致性损失，$\mathcal{L}_{\text{motion}}$ 和 $\mathcal{L}_{\text{reg}}$ 分别约束连续运动及局部几何变形。通过轨迹、渲染和几何信息的联合约束，使连续运动估计与三维高斯重建相互校正。

优化采用交替更新策略：首先利用重投影及渲染残差评估当前几何与运动估计，更新观测可靠性；随后根据局部时间支持和运动误差调整轨迹表达复杂度及正则强度；最后联合更新连续运动参数与三维高斯几何，逐步改善跨时刻一致性和非采样时刻的恢复精度。

针对遮挡及时间采样不足的区域，进一步通过不同观测子集或初始化获得多组候选轨迹，并根据其估计分歧描述局部运动不确定性：

$$U_j(t) = \frac{1}{S}\sum_{s=1}^{S}\left\|\mathbf{p}_j^{(s)}(t) - \bar{\mathbf{p}}_j(t)\right\|_2^2, \tag{13}$$

其中，$\mathbf{p}_j^{(s)}(t)$ 为第 s 组候选轨迹，$\bar{\mathbf{p}}_j(t)$ 为其均值，S 为候选数量。结合有效观测支持 $H_j(t)$ 与运动分歧 $U_j(t)$，评估弱观测区域的运动估计稳定性，并指导局部运动约束与几何更新。随着新增观测到来，持续修正观测权重、连续运动及三维几何。

最终形成由几何 $\mathcal{G}(t)$、外观 $\mathcal{C}(t)$ 和连续运动 $\mathcal{M}(t)$ 构成的动态场景表征，支持建模时间范围内的连续状态查询。拟通过不同时间采样密度、遮挡程度和运动复杂度下的受控实验，结合运动轨迹精度、非采样时刻重建质量及关键机制消融，验证观测可靠性建模、自适应运动表达和几何—运动联合优化的作用。

3.3.2 连续运动引导的对象时空一致性建模



图 11 连续运动引导的对象时空一致性建模技术路线

本项研究面向遮挡、短时共动及局部形变条件下的对象时空一致性建模，采用“多证据空间关联—部件软归属与身份维护—归属约束的联合恢复”的技术路线，如图 11 所示。首先利用连续运动、几何、外观与可见性建立具有可靠性评估的空间关联；随后通过部件身份锚点与软归属维护跨时刻空间组织，并根据观测证据更新待定关系；最后结合身份兼容和运动兼容约束局部信息共享，通过几何、运动与空间归属的联合优化，形成具有持续对象身份和时空一致性的动态场景表征。

（1）多证据空间关联

以第一项研究获得的几何 $\mathcal{G}(t)$、外观 $\mathcal{C}(t)$ 和连续运动 $\mathcal{M}(t)$ 为基础，将高斯图元及其运动轨迹组织为基本场景单元。首先根据空间邻近、轨迹覆盖及局部几何关系构建候选关联邻域，再结合长期相对运动、外观相似性和可见性信息，评价候选单元之间的空间关联。

考虑不同对象可能在部分时间区间内共同运动，而同一对象的不同部件也可能存在相对运动，拟利用较长时间范围内的运动变化及多线索一致性判断关联关系。设 $\Omega_{ij}(t)$ 为截至时刻 t 用于分析场景单元 i 和 j 的有效观测窗口集合，分别累积支持共同部件归属与不同部件归属的证据：

$$S_{ij}^{\pm}(t)=\sum_{\tau\in\Omega_{ij}(t)}\eta_{ij,\tau}e_{ij,\tau}^{\pm}, \tag{14}$$

其中，$e_{ij,\tau}^{+}$ 和 $e_{ij,\tau}^{-}$ 分别表示相应时间窗口内的正向关联与冲突证据，$\eta_{ij,\tau}$ 为结合轨迹可靠性、几何一致性及可见性确定的观测权重。通过多时刻证据积累，综合利用共同运动、相对运动变化和空间几何关系，提高关联判断的稳定性。

进一步考虑有效时间覆盖及不同关联解释之间的证据差异，构建关联可靠性：

$$r_{ij}(t)=\frac{h_{ij}(t)}{h_{ij}(t)+\tau_0}\frac{\left|S_{ij}^{+}(t)-S_{ij}^{-}(t)\right|}{S_{ij}^{+}(t)+S_{ij}^{-}(t)+\epsilon}, \tag{15}$$

其中，$h_{ij}(t)$ 描述有效时间覆盖及运动变化提供的区分信息，τ_0 为调节参数，ϵ 为数值稳定项。利用 $r_{ij}(t)$ 对正向关联与冲突证据进行加权，建立带置信度的空间关联图 $\mathcal{H}(t)$，分别维护可信关联、冲突关系及待定关系。该关联图能够随新增观测持续更新，为对象及部件的空间组织提供多时刻证据。

（2）部件软归属与身份维护

在空间关联图的基础上，结合视觉基础模型提供的对象及部件分割先验，选择具有稳定跨时刻对应、较高观测覆盖和一致几何特征的场景单元作为身份锚点，并通过关联传播维护持续对象身份。考虑遮挡和局部形变引起的身份歧义，采用对象—部件层次化软归属表示，使对象级身份与部件级空间组织能够分别维护。

设当前存在 K 个部件身份候选，对场景单元 i 定义软归属向量：

$$\mathbf{q}_i(t)=\left[q_{i,0}(t),q_{i,1}(t),\ldots,q_{i,K}(t)\right],\qquad \sum_{k=0}^{K}q_{i,k}(t)=1, \tag{16}$$

其中，$q_{i,k}(t)$ 表示单元 i 归属于部件 k 的估计程度，$q_{i,0}(t)$ 表示当前归属待定。不同部件可通过层次关系关联到同一对象身份，从而同时描述对象身份的持续性与内部部件的相对运动。

综合身份锚点、空间关联与时序对应，建立软归属优化目标：

$$\begin{aligned}\mathcal{L}_{\text{attr}} = & \sum_{i\in\mathcal{S}} c_i \,\mathrm{CE}\left(\tilde{z}_i, \mathbf{q}_i\right) \\ & + \lambda_{+} \sum_{(i,j)\in\mathcal{A}^{+}} A_{ij}^{+} \left\|\mathbf{q}_i^{*} - \mathbf{q}_j^{*}\right\|_2^2 \\ & + \lambda_{-} \sum_{(i,j)\in\mathcal{A}^{-}} A_{ij}^{-} \left\langle \mathbf{q}_i^{*}, \mathbf{q}_j^{*} \right\rangle \\ & + \lambda_{\text{temp}}\mathcal{L}_{\text{temp}} + \lambda_{\text{unk}}\mathcal{L}_{\text{unk}},\end{aligned} \tag{17}$$

其中，$\mathcal{S}$ 为可靠身份锚点集合，$\tilde{z}_i$ 和 c_i 分别表示锚点身份先验及其可靠性，$\mathbf{q}_i^{*}$ 为已知部件的归属分量；$\mathcal{A}^{+}$、$\mathcal{A}^{-}$ 及其权重 A_{ij}^{+}、A_{ij}^{-} 分别表示可信关联和冲突关系。$\mathcal{L}_{\text{temp}}$ 用于保持可靠对应下的身份连续性，$\mathcal{L}_{\text{unk}}$ 根据归属证据调节待定状态。通过正反关联约束与持续身份锚点相结合，提高遮挡和复杂运动条件下的空间归属一致性。

对于遮挡后重新出现的对象，利用持续身份、运动历史和外观特征恢复关联；对于首次显露的已有表面，结合当前几何与运动预测建立候选归属，并利用后续观测逐步完善空间组织。通过持续更新身份锚点和软归属关系，维护对象及部件的跨时刻一致性。

（3）归属约束的联合恢复

在建立对象及部件的空间归属后，进一步利用归属关系约束运动与几何信息的共享范围。考虑同一对象内部可能存在不同部件运动，而不同对象也可能短时共同运动，本项研究分别建立身份兼容与运动兼容约束，使运动信息的共享同时受到空间归属和局部运动一致性的控制。

设几何单元 i 与运动支撑节点 j 的基础关联权重为 α_{ij}，由部件软归属计算身份兼容程度 $g_{ij}^{\text{id}}(t) = \sum_{k=1}^{K} q_{i,k}(t) q_{j,k}(t)$，并根据局部轨迹和几何运动残差估计运动兼容程度 $g_{ij}^{\text{mot}}(t)$。综合两类约束，构建运动共享权重：

$$\tilde{\alpha}_{ij}(t) = \frac{\alpha_{ij} g_{ij}^{\text{id}}(t) g_{ij}^{\text{mot}}(t)}{\sum_{\ell\in\mathcal{N}(i)} \alpha_{i\ell} g_{i\ell}^{\text{id}}(t) g_{i\ell}^{\text{mot}}(t)}, \tag{18}$$

其中，$\mathcal{N}(i)$ 为几何单元 i 的候选运动支撑集合，α_{ij} 取自连续时间变形模型的局部运动关联。在具备有效共享支持的区域，利用 $\tilde{\alpha}_{ij}(t)$ 更新图元变形；对于归属待定或缺少可靠运动支持的区域，则采用局部运动估计维持几何状态。通过身份与运动兼容约束的协同作用，改善跨对象运动混合及部件运动表达。

以第一项研究的几何—运动联合恢复目标为基础，进一步引入空间归属约束，构建联合优化模型：

$$\min_{\Theta_G,\Theta_C,\Theta_M,\Theta_Z} \quad \mathcal{L}_{\text{joint}} = \mathcal{L}_{\text{base}}\left(\Theta_G,\Theta_C,\Theta_M;\tilde{\alpha}\right) + \lambda_{\text{attr}}\mathcal{L}_{\text{attr}}, \tag{19}$$

其中，$\mathcal{L}_{\text{base}}$ 为连续运动与三维几何的联合恢复目标，Θ_Z 为软归属参数，$\tilde{\alpha}$ 随归属及运动状态更新。该目标将对象组织与动态几何恢复纳入统一求解过程，使空间归属约束运动信息共享，连续运动与几何恢复结果则为归属更新提供反馈。

优化采用交替更新策略：首先根据几何和运动估计重新评价空间关联及冲突证据；随后结合可靠身份锚点更新部件软归属；最后根据身份与运动兼容关系调整共享权重，联合更新连续运动和三维几何。通过多轮双向校正，逐步改善对象身份、局部运动与空间几何之间的一致性。

最终形成具有持续对象及部件身份、软归属 $\mathcal{Z}(t)$ 和有效信息共享范围的动态表征，并同步完善几何 $\mathcal{G}(t)$ 与连续运动 $\mathcal{M}(t)$。拟通过长期共动、部件相对运动、遮挡及首次显露等受控场景，结合身份关联精度、运动恢复质量和关键机制消融，验证长期运动证据、软归属维护及共享约束对时空一致性建模的作用。

3.3.3 物理连接变化下的动态结构表征与更新



图 12 物理连接变化下的动态结构表征与更新技术路线

本项研究面向切割、撕裂等物理连接变化引起的动态结构更新问题，采用“局部连接与结构变化判断—连接约束与表面局部更新—材料与表面双历史维护”的技术路线。首先结合连续运动、局部几何及边界变化证据，估计物理连接的保持与失效状态；

随后根据连接状态调整局部运动与几何约束，恢复变化区域的三维结构；最后分别维护材料运动历史与表面存在历史，协调结构变化后的状态更新与有效历史延续。具体技术路线如图 12 所示。

（1）局部连接与结构变化判断

在已有连续动态场景表征的基础上，结合对象及部件的空间归属、局部表面几何与连续运动轨迹，构建候选物理连接集合 $\mathcal{E}_{\text{cand}}$。对于候选连接 e_{ij}，利用相邻区域的相对运动、几何间隙、表面边界及跨时刻可见性变化，分析其物理连接状态随时间的变化。

为判断原有连接是否发生失效，拟针对局部候选连接建立连接保持与连接解除两种结构假设，分别计算其对当前时序观测的解释误差，并综合区域分离及边界变化证据构建连接变化评分：

$$\begin{aligned} D_{ij}(t) = \mathcal{L}_{ij}^{\text{keep}}(t) - \mathcal{L}_{ij}^{\text{release}}(t) \\ - \lambda_{\text{cmp}}\Delta\mathcal{C}_{ij} + \lambda_{\text{sep}}S_{ij}(t) + \lambda_{\text{bd}}B_{ij}(t), \end{aligned} \tag{20}$$

其中，$\mathcal{L}_{ij}^{\text{keep}}$ 和 $\mathcal{L}_{ij}^{\text{release}}$ 分别表示保留与解除原有连接约束时的局部观测拟合误差，$\Delta\mathcal{C}_{ij}$ 表示解除约束所增加的模型复杂度，$S_{ij}(t)$ 与 $B_{ij}(t)$ 分别描述相对分离和新边界证据。通过比较不同连接假设的观测解释能力，结合时序证据判断局部物理连接变化。

进一步根据连接变化评分估计连接支持程度，并维护连接状态：

$$p_{ij}^{\text{conn}}(t) = \sigma\big(-\gamma D_{ij}(t)\big), \tag{21}$$

其中，$p_{ij}^{\text{conn}}(t)$ 表示候选连接保持有效的支持程度，γ 为评分尺度参数。结合连接支持及其时间变化，区分连接保持、连接失效与待定关系，并通过连续多时刻的几何和运动证据更新连接状态。由此形成局部结构变化区域及候选连接状态，为后续约束调整和表面恢复提供依据。

（2）连接约束与表面局部更新

在连接状态估计的基础上，将物理连接关系引入动态几何与运动优化。对于具有有效物理连接的相邻区域，利用局部几何连续性与运动协调关系建立约束；当连接发生失效时，相应减弱或解除跨连接区域的运动及几何约束，使原先连接的区域能够独立运动。

设 $\ell_{ij}^{\text{coh}}(t)$ 表示候选连接 e_{ij} 对应的局部几何与运动协调误差，构建随物理连接状态变化的结构约束：

$$\mathcal{L}_{\text{conn}} = \sum_{e_{ij}\in\mathcal{E}_{\text{cand}}} \int_{\mathcal{T}} p_{ij}^{\text{conn}}(t)\ell_{ij}^{\text{coh}}(t)\,\mathrm{d}t, \tag{22}$$

其中，$\mathcal{T}$ 为建模时间范围。ℓ_{ij}^{coh} 可根据局部运动特征采用几何连续性、相对形变或运动协调约束。通过连接状态对约束强度进行调节，使运动模型能够适应局部连接关系的变化。

针对连接变化后的局部几何更新，利用表面代理确定变化区域 Ω_{change}，结合新增观测恢复变化后的几何边界与表面结构。对于切割、撕裂等事件形成的新生表面，初

始化相应的几何图元及外观参数；对于遮挡解除后首次显露的已有表面，则利用现有几何与运动历史建立关联并补充观测信息。通过区分不同表面更新情形，维护变化区域的动态三维几何。

为协调局部结构更新与稳定区域的状态保持，构建局部联合优化目标：

$$\begin{aligned}\min_{\Theta_\Omega} \quad & \mathcal{L}_{\text{local}} = \mathcal{L}_{\text{obs}}^{\Omega} + \lambda_{\text{conn}}\mathcal{L}_{\text{conn}}^{\Omega} \\ & + \lambda_{\text{stable}}\mathcal{L}_{\text{stable}},\end{aligned} \tag{23}$$

其中，Θ_Ω 为变化区域及其邻域内待更新的几何、外观与运动参数，$\mathcal{L}_{\text{obs}}^{\Omega}$ 综合局部图像、深度及轨迹观测约束，$\mathcal{L}_{\text{conn}}^{\Omega}$ 为局部有效连接约束，$\mathcal{L}_{\text{stable}}$ 用于保持稳定区域及边界邻域内已有几何与运动状态的一致性。

优化过程中交替更新连接状态、局部运动参数和表面几何：首先利用连续运动及观测残差重新评估连接变化证据，随后调整相关区域的共享运动和几何约束，再对变化区域进行局部图元更新与联合优化。通过局部结构约束重配置与几何恢复相结合，实现物理连接变化后的动态场景更新，并保持稳定区域的连续运动与几何信息。

（3）材料与表面双历史维护

物理连接变化不仅影响当前结构，也会改变历史约束对后续状态估计的作用范围。为协调连接变化前后的运动连续性与表面几何更新，拟分别维护材料运动历史与表面存在历史。

其中，材料运动历史描述稳定材料单元或局部运动锚点在不同时间的空间轨迹，用于延续物理连接变化前已有的运动信息；表面存在历史则描述各局部表面的形成时间、有效区间及可见性变化。相应的双历史表示定义为

$$\begin{aligned}\mathcal{H}(t) &= \left(\{\mathcal{T}_i^{\text{mat}}\}, \{\mathcal{B}_s^{\text{surf}}\}\right), \\ \mathcal{T}_i^{\text{mat}} &= \{(\tau, \mathbf{x}_i(\tau))\}, \\ \mathcal{B}_s^{\text{surf}} &= \left(t_s^{\text{birth}}, t_s^{\text{end}}, v_s(\tau)\right),\end{aligned} \tag{24}$$

其中，$\mathcal{T}_i^{\text{mat}}$ 为材料单元 i 的有效运动历史，$\mathcal{B}_s^{\text{surf}}$ 描述表面区域 s 的存在区间及可见性，t_s^{birth} 和 t_s^{end} 分别为其形成与终止时刻，$v_s(\tau)$ 表示对应时刻的可见状态。

当物理连接发生变化时，已有材料单元的运动历史继续保留，而跨失效连接的运动协调约束在事件后重新配置。对于新生物理边界，从结构事件发生时建立新的表面历史；对于首次显露的已有表面，延续其原有结构关系并补充新的可见观测。由此分别维护材料轨迹的时间连续性与表面几何的存在关系。

进一步根据连接状态及结构事件时刻，建立历史约束的有效性管理机制。对于跨时间区间的运动与几何约束，结合其所依赖的物理连接是否持续有效，确定历史信息的参与范围；对于稳定区域保留已有运动与几何约束，对于连接变化区域则更新相关约束并重新组织局部表面历史。

通过连接状态更新、局部几何恢复与双历史维护的迭代协调，形成适应物理连接变化的动态场景表征。最终获得更新后的几何 $\mathcal{G}(t)$、外观 $\mathcal{C}(t)$、连续运动 $\mathcal{M}(t)$、对象

归属 $\mathcal{Z}(t)$ 和物理连接状态 $\mathcal{E}(t)$。拟通过连接变化时刻、局部边界几何、运动轨迹及稳定区域历史保持等指标，结合结构事件前后的受控实验和机制消融，验证局部约束更新与双历史维护对动态结构重建的作用。

3.3.4 动作后果预测与连续动态表征协同建模

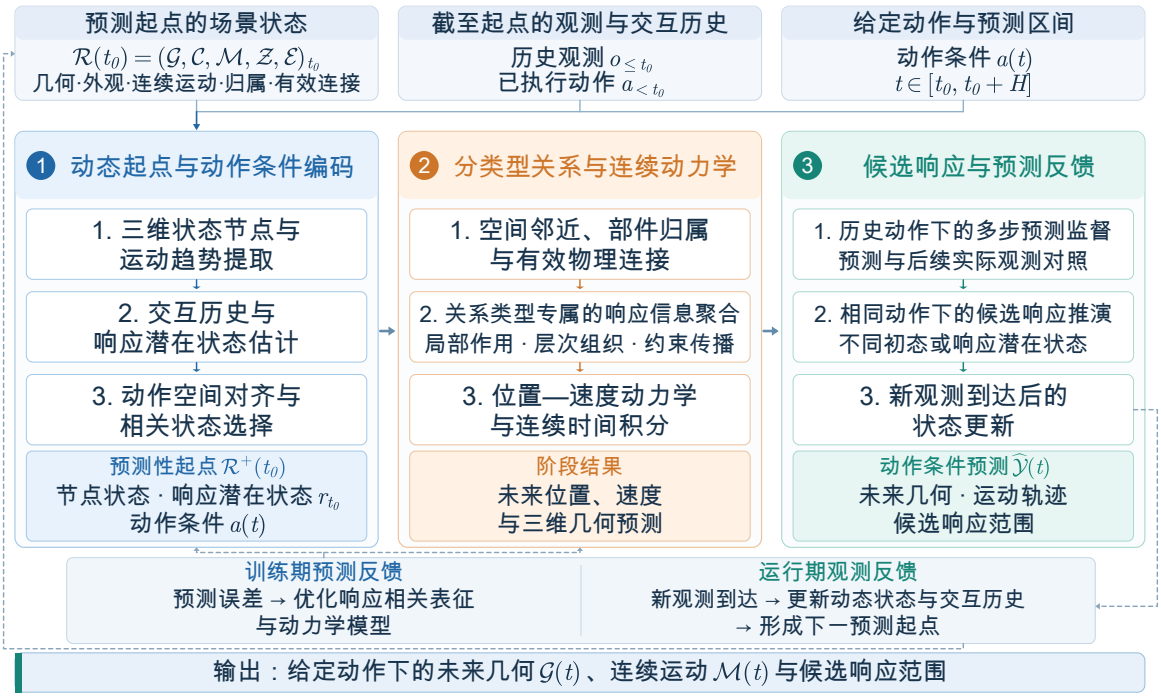


图 13 动作后果预测与连续动态表征协同建模技术路线

本项研究面向连续动态场景中的动作后果预测，采用“动态起点与动作条件编码—分类型关系与连续动力学—候选响应与预测反馈”的技术路线，如图 13 所示。首先结合连续动态场景表征及交互历史，构建包含几何、运动、空间结构和响应相关状态的预测起点；随后利用分类型关系组织局部作用与响应传播，建立动作条件下的连续时间动力学模型；最后通过多步预测监督、候选响应推演及观测反馈，使动态状态表征与未来演化预测相互约束，形成可随交互过程持续更新的预测性世界模型。

（1）动态起点与动作条件编码

以预测起点 t_0 的连续动态场景表征 $\mathcal{R}(t_0)$ 为基础，提取具有稳定几何和运动信息的三维状态节点。对于节点 i，构建包含三维位置 $\mathbf{x}_i(t_0)$、瞬时速度 $\mathbf{v}_i(t_0)$、局部几何与外观特征以及对象或部件归属的节点状态 $\mathbf{s}_i(t_0)$。其中，瞬时速度由连续时间运动表征求导获得，物理连接信息通过节点之间的结构关系表达。通过上述状态组织，将连续动态场景转换为适用于后续动力学预测的结构化初始条件。

考虑动作响应不仅受到当前几何与运动状态影响，还与已有交互过程中表现出的响应特性有关，拟结合截至预测起点的观测及已执行动作，学习响应相关潜在状态：

$$r_{t_0}=F_\phi\left(\mathcal{R}(t_0),\mathcal{O}_{\le t_0},\mathcal{A}_{<t_0}\right), \tag{25}$$

其中，$\mathcal{O}_{\le t_0}$ 和 $\mathcal{A}_{<t_0}$ 分别表示截至预测起点的观测历史与已执行动作历史，F_ϕ 为响应状态编码模型。潜在状态 r_{t_0} 用于整合已有交互中反映的动力学及响应信息，与基础动态表征共同构成预测性世界状态 $\mathcal{R}^+(t_0)$。

对于给定的未来动作 $a(t)$，进一步根据动作类型、作用位置、持续时间及当前空间结构，将动作条件映射到相关三维状态节点。通过动作空间对齐与相关状态选择，构建节点级动作输入 $\mathbf{a}_i(t)$，使动力学模型能够区分直接受到动作作用的区域以及通过空间关系产生间接响应的区域。由此形成包含节点状态、响应相关潜在状态及动作条件的预测起点。

（2）分类型关系与连续动力学

在结构化预测起点的基础上，利用场景几何、对象归属及物理连接状态建立分类型空间关系。具体考虑空间邻近、对象或部件归属以及有效物理连接三类关系，分别描述局部空间作用、层次化运动组织与持续物理约束。通过不同关系类型组织状态节点之间的信息传递，使动作影响能够沿相应的空间与结构关系传播。

设关系类型集合为 $\mathcal{Q}$，对于节点 i，构建类型专属的响应信息聚合：

$$\mathbf{m}_i^{(r)}(t) = \sum_{j\in\mathcal{N}_r(i,t)} w_{ij}^{(r)}(t)\phi_r\left(\mathbf{s}_i(t), \mathbf{s}_j(t), \mathbf{x}_j(t) - \mathbf{x}_i(t)\right), \quad r \in \mathcal{Q}, \tag{26}$$

其中，$\mathcal{N}_r(i,t)$ 为节点 i 在关系类型 r 下的关联邻域，$w_{ij}^{(r)}(t)$ 表示关系的有效程度，ϕ_r 为对应关系类型的消息函数。空间邻近关系根据预测过程中的几何位置更新，对象及部件关系提供层次化状态信息，物理连接关系则依据预测起点的有效连接状态约束响应传播。通过关系类型专属的参数化与信息聚合，学习不同结构关系对局部运动和动作影响传播的作用。

进一步以节点的位置和速度作为主要动态变量，结合关系信息、响应潜在状态及动作条件，建立连续时间动力学模型：

$$\begin{aligned} \frac{\mathrm{d}\mathbf{x}_i(t)}{\mathrm{d}t} &= \mathbf{v}_i(t), \\ \frac{\mathrm{d}\mathbf{v}_i(t)}{\mathrm{d}t} &= f_\theta\left(\mathbf{s}_i(t), \{\mathbf{m}_i^{(r)}(t)\}_{r\in\mathcal{Q}}, \mathbf{a}_i(t), r_{t_0}\right), \end{aligned} \tag{27}$$

其中，f_θ 为动作条件动力学模型，预测当前节点在局部状态、空间关系及外部动作作用下的速度变化率。通过连续时间数值积分获得未来节点的位置与速度轨迹，再利用节点运动驱动对应三维几何单元，恢复未来场景的动态几何与连续运动状态。

该模型将已有运动趋势作为动态初始条件，并通过分类型关系描述不同区域之间的响应传递，使未来运动预测同时受到几何、空间组织、有效物理连接及交互历史的约束。通过对不同关系类型及状态信息的联合建模，研究连续动态表征对动作后果预测的作用。

（3）候选响应与预测反馈

在动作条件动力学模型的基础上，利用包含动作记录和后续观测的交互序列开展多步预测训练。对于每个预测起点，仅根据截至该时刻的状态与交互历史形成初始条

件，在给定后续动作序列下递推预测未来三维位置、运动轨迹及几何变化，并将预测结果与相应时间的观测进行比较。

考虑有限观测可能对应不同的初始运动估计和响应相关潜在状态，进一步构建多组候选预测起点，在相同动作条件下分别进行连续动力学推演：

$$\widehat{\mathcal{Y}}_{t_0:t_0+H}^{(s)} = \mathrm{Rollout}_\theta\left(\mathbf{S}_{t_0}^{(s)}, r_{t_0}^{(s)}, a_{t_0:t_0+H}\right), \tag{28}$$

其中，$\mathbf{S}_{t_0}^{(s)}$ 和 $r_{t_0}^{(s)}$ 分别表示第 s 组候选初始节点状态与响应潜在状态，$a_{t_0:t_0+H}$ 为给定动作序列，$\mathrm{Rollout}_\theta$ 表示连续动力学积分与几何恢复过程。通过比较不同候选起点在相同动作下的演化结果，获得未来几何、运动轨迹及候选响应范围，并分析初始状态差异对预测结果的影响。

为使动态表征与动作预测相互促进，拟将多步预测监督与已有观测下的状态恢复约束相结合，构建协同优化目标：

$$\begin{aligned}\min_{\theta,\phi,\Theta_R} \quad & \mathcal{L}_{\mathrm{joint}} = \lambda_{\mathrm{traj}}\mathcal{L}_{\mathrm{traj}} + \lambda_{\mathrm{render}}\mathcal{L}_{\mathrm{render}} \\ & \qquad + \lambda_{\mathrm{hist}}\mathcal{L}_{\mathrm{hist}} + \lambda_{\mathrm{reg}}\mathcal{L}_{\mathrm{reg}},\end{aligned} \tag{29}$$

其中，θ 和 ϕ 分别为动力学模型与响应状态编码模型的参数，Θ_R 表示参与协同优化的动态表征参数。$\mathcal{L}_{\mathrm{traj}}$ 约束多步预测轨迹，$\mathcal{L}_{\mathrm{render}}$ 利用未来图像及可用深度观测约束预测几何，$\mathcal{L}_{\mathrm{hist}}$ 保持已有观测下的几何与运动一致性，$\mathcal{L}_{\mathrm{reg}}$ 为动力学及响应潜在状态的正则约束。对于具有可靠三维轨迹参考的序列，引入三维运动监督；对于主要提供视觉观测的序列，则利用投影轨迹与可微渲染建立预测约束。

优化采用分阶段训练与联合调整相结合的方式：首先基于已有连续动态状态训练响应状态编码与动作条件动力学模型，建立稳定的未来演化预测；随后利用多步预测误差联合优化响应相关潜在状态及可训练的动态表征参数，使内部状态进一步保留影响动作响应的信息，同时维持已有观测下的几何与运动一致性。

在连续交互过程中，模型保存当前预测结果；当新观测及动作执行反馈到达后，更新动态场景状态与交互历史，并估计新的响应相关潜在状态，形成下一预测起点。通过预测监督与观测更新两个过程，建立动态状态维护、动作条件演化预测及实际反馈相联系的时序闭环。

最终形成给定动作条件下的未来几何 $\widehat{\mathcal{G}}(t)$、连续运动 $\widehat{\mathcal{M}}(t)$ 及候选响应范围。拟通过多步三维轨迹预测、未来几何重建及不同动作条件下的受控实验，结合状态分量消融与估计误差扰动，分析连续运动、对象归属、物理连接和响应潜在状态对预测结果的作用，验证动态表征与动作条件预测协同建模的有效性。

2. 研究计划可行性，研究条件落实情况，可能存在的问题及解决办法（可续页）

3.4 研究计划可行性分析

本课题以已有动态场景建模和动作条件表征学习的探索为起点，围绕连续时间表征、空间结构、连接变化和动作响应四项研究逐步推进。研究计划的可行性主要体现在方法依据、前期积累和分阶段实施三个方面。

理论与方法依据。连续时间运动表达、跨时刻空间关联、动态表面建模及动作条件演化均已有研究基础，为本课题提供了可借鉴的表示方式与实现途径。在此基础上，本课题以共同表征组织几何、运动、归属和连接信息，分别研究观测约束、结构更新与动作响应。各项方法具有可区分的输入、输出和评价依据，可以依托已有方法逐项实现，并通过对照分析各机制的作用。

前期工作积累。前文介绍的 CoFuse4D 探索了带噪对应融合、有限复杂度运动支撑和时间建模，为连续运动恢复及多时刻几何利用提供实现经验；PS-VLA 探索了动作条件状态转移与观测更新，为表征预测及操作模型的研究提供基础。两项工作尚未发表，其积累主要用于建立研究起点；空间归属、真实结构变化及连续表征对动作预测的作用仍需在本课题中研究和验证。

实施与验证路径。四项研究可先依托已有表示及可用数据独立开展，分别检验关键机制，再通过共同表征接口逐步衔接。实验先从观测和参考条件较明确的场景入手，逐步扩展到遮挡、结构变化及交互过程；通过固定输入或响应模型的对照，分析表征质量与后续预测之间的关系。若某项机制尚未稳定，可先采用已有表征或简化条件完成其他分项验证，再逐步增加研究环节。上述安排有利于识别各项方法的作用、适用条件及误差传递来源。

3.5 研究条件落实情况

本课题依托陕西省信息获取与处理重点实验室开展。实验室的计算资源、已有研究的软件基础及公开数据资源，可支撑算法开发、模型训练和可复现的比较实验。

计算与软件条件：实验室配备 NVIDIA RTX PRO 6000D GPU x16（单卡显存为 84 GB），计算资源较为充裕。前期动态场景与动作学习研究已积累相关的数据处理、建模和评测软件基础，可用于建立本课题的实验流程。后续将依据模型规模和实验需要配置计算资源，记录软件依赖、训练设置和运行条件，以支持比较实验与结果复现。

数据与验证条件：围绕连续时间恢复、空间结构、连接变化及动作响应四项研究，前期已对公开动态数据、点跟踪数据及交互操作数据的采集条件、标注类型和评价方式进行调研和核对。表 1 汇总了各候选数据源的类型、主要观测与参考、适用验证及使用条件；所覆盖的真实动态观测、带轨迹标注的合成序列及动作条件交互片段可支撑各项研究的训练、比较与验证。研究按各数据源已有的划分、标注和评测协议组织实验，利用已有工具建立共同流程。对结构变化等参考较少的条件，分别说明可评价分量与证据范围，随公开资源及方法进展完善验证。

表 1 公开数据源的主要特性及适用验证

数据源及类型	主要观测与参考	适用验证	使用条件与限制
DyCheck （真实单目）[38]	RGB 视频、相机与深度、 共可见掩膜、关键点	连续恢复；图像/运动评价	视角与深度随序列变化
PointOdyssey （合成）[41]	RGB-D、相机、 实例标注及二维/三维长时轨迹	运动恢复与空间归属、 长时跟踪	合成域；实例非部件级
Nerfies-HyperNeRF （真实多视角）[19, 21]	动态视频、多视角序列； 训练/测试划分	留出观测恢复与结构更新	连接及新生表面无真值
DROID （真实交互）[83]	多视角视频与动作记录	真实场景动作预测检验	需筛选含历史及后续 观测片段
PointWorld-DROID （真实派生）[11]	三维点轨迹 及有效性标记（自动估计）	动作条件下轨迹/几何评价	轨迹按带误差参考单列
PhysTwin （真实视频）[12]	多视角视频、重建与仿真结果	形变对象动作响应预测	重建/仿真非独立真值

3.6 可能存在的问题及解决办法

本课题涉及动态场景建模与演化预测，研究过程中可能面临数据、算力及研究实施等方面的困难，拟采取以下措施加以解决。

（1） **相关数据资源不足。**复杂动态场景的公开数据及标注资源相对有限，可能难以充分支撑模型训练与验证。拟结合公开数据集、仿真数据及必要的自主采集，逐步完善实验数据，并通过多种场景的对比实验验证方法的有效性。

（2） **计算资源与实验成本较高。**动态世界建模涉及较大规模的时空数据处理与模型训练，可能受到计算资源和实验周期的限制。拟充分利用已有预训练模型与计算平台，采用分阶段训练、模块化验证及实验规模控制等方式，提高研究效率。

（3） **研究内容较多，整体实施存在不确定性。**本课题涉及多个相互关联的研究内容，部分研究任务可能面临实现难度较大、实验效果不及预期等问题。拟按照研究计划分阶段推进，优先完成关键方法验证，并根据阶段性成果适当调整技术路线和研究重点，保障课题顺利开展。

3. 研究计划及预期成果

	起止年月	完成内容
研究计划	**2026.10–2027.03**	完成开题及相关文献梳理，完善 CoFuse4D 和 PS-VLA 前期工作并按进展投稿；建立实验基础，研究观测置信度约束的连续运动恢复，开展初步比较。形成开题报告、实验基线和阶段论文稿件。
	2027.04–2027.09	完善不确定性感知的连续时间场景表征，分析采样和观测质量的影响；研究连续运动引导的空间归属与结构组织，开展多场景比较和关键消融。形成方法实现、实验分析及阶段研究稿件。
	2027.10–2028.03	研究结构变化下的局部连接及表面更新，开展公开序列上的比较与历史维护消融；并行开展动态初始条件下的动作后果预测建模。形成拓扑适应和动作预测的阶段方法及实验结果。
	2028.04–2028.10	完善公开交互数据上的动作响应预测验证，开展模型衔接、误差传递和失败情形分析；整理研究成果，完成博士学位论文撰写与修改，按学校安排推进送审及答辩。形成研究原型、可复核验证协议及论文。

3.7 预期创新点及成果形式

本课题预期形成连续动态世界模型构建方法及研究原型，积累可复核的比较、消融与误差分析结果，形成学术论文和博士学位论文。拟取得的创新性认识与方法进展如下，其有效性和成立范围通过上述验证确定。

（1）**观测支持与时间表达能力的联合配置机制。**将观测置信度、有效时间覆盖及局部运动自由度纳入同一求解过程，研究证据强弱与表达能力的匹配关系，形成兼顾非采样时刻恢复和快速运动保持的连续时间表征方法。

（2）**连续运动与空间归属的双向约束机制。**以持续相对运动联合几何、外观和可见性推断软归属，再由归属限定共享约束，形成运动、几何与空间组织相互校正的方法，阐明遮挡和短时共动下信息共享的有效条件。

（3）**结构变化下局部更新与历史延续的协调机制。**分别维护连接支持、材料运动关联与表面存在区间，协调失效约束解除、新生边界表达和稳定区信息保持，形成面向观测支持的局部结构变化的连续动态表征方法。

（4）**运动与当前结构约束的动作响应建模机制。**从相同历史构建动态初始信息，通过分类型关系组织响应并传播关键解释分歧，研究运动、归属和连接对预测的作用及误差传递，明确连续动态表征的有效条件与可替代范围。

备注	

四、参考文献

[1] HA D, SCHMIDHUBER J. Recurrent World Models Facilitate Policy Evolution[C]//Advances in Neural Information Processing Systems: Vol. 31. Curran Associates, Inc., 2018.

[2] HAFNER D, PASUKONIS J, BA J, et al. Mastering diverse control tasks through world models [J/OL]. Nature, 2025, 640(8059): 647-653. DOI: 10.1038/s41586-025-08744-2.

[3] 国家自然科学基金委员会信息科学部. 关于发布 2026 年度国家自然科学基金“空间智能与世界模型”专项项目申请指南的通告[EB/OL]. 2026.

[4] National Science Foundation. CAREER: From Language Models to World Models: New Inference, Learning, and Modeling for Machine Reasoning: No. 2443468[EB/OL]. 2025.

[5] PARKER-HOLDER J, FRUCHTER S. Genie 3: A new frontier for world models[EB/OL]. Google DeepMind, 2025.

[6] NVIDIA. NVIDIA Launches Cosmos World Foundation Model Platform to Accelerate Physical AI Development[EB/OL]. 2025.

[7] National Aeronautics and Space Administration. Robotic Refueling Mission (RRM) 1 & 2[EB/OL]. NASA, 2026.

[8] WANG X, MA L, SHEN Y, et al. RetimeGS: Continuous-Time Reconstruction of 4D Gaussian Splatting[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026: 7340-7350.

[9] WU J, NGUYEN V N, PLANCHE B, et al. Consistent Instance Field for Dynamic Scene Understanding[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026: 3783-3793.

[10] ZHENG C, XUE L, ZARATE J, et al. GauSTAR: Gaussian Surface Tracking and Reconstruction [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 16543-16553.

[11] HUANG W, CHAO Y W, MOUSAVIAN A, et al. PointWorld: Scaling 3D World Models for In-The-Wild Robotic Manipulation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026: 20765-20779.

[12] JIANG H, HSU H Y, ZHANG K, et al. PhysTwin: Physics-Informed Reconstruction and Simulation of Deformable Objects from Videos[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 7219-7230.

[13] 孙水发, 汤永恒, 王奔, 等. 动态场景的三维重建研究综述[J/OL]. 计算机科学与探索, 2024, 18 (4): 831-860. DOI: 10.3778/j.issn.1673-9418.2305016.

[14] 陈涛, 杨启亮, 陈寅. 神经辐射场技术及应用综述[J/OL]. 计算机辅助设计与图形学学报, 2025, 37(1): 51-74. DOI: 10.3724/SP.J.1089.2023-00759.

[15] 连振晗, 王章野, 牛炯, 等. 基于三维高斯泼溅的动态场景重建研究综述[J/OL]. 计算机辅助设计与图形学学报, 2026, 38(1): 61-77. DOI: 10.3724/SP.J.1089.2025-00251.

[16] NEWCOMBE R A, FOX D, SEITZ S M. DynamicFusion: Reconstruction and Tracking of Non-Rigid Scenes in Real-Time[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 343-352.

[17] MILDENHALL B, SRINIVASAN P P, TANCIK M, et al. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis[C/OL]//Computer Vision – ECCV 2020: Vol. 12346. Springer, 2020: 405-421. DOI: 10.1007/978-3-030-58452-8_24.

[18] PUMAROLA A, CORONA E, PONS-MOLL G, et al. D-NeRF: Neural Radiance Fields for Dynamic Scenes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 10318-10327.

[19] PARK K, SINHA U, BARRON J T, et al. Nerfies: Deformable Neural Radiance Fields[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 5865-5874.

[20] LI Z, NIKLAUS S, SNAVELY N, et al. Neural Scene Flow Fields for Space-Time View Synthesis of Dynamic Scenes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 6498-6508.

[21] PARK K, SINHA U, HEDMAN P, et al. HyperNeRF: A Higher-Dimensional Representation for Topologically Varying Neural Radiance Fields[J/OL]. ACM Transactions on Graphics, 2021, 40(6): 238:1-238:12. DOI: 10.1145/3478513.3480487.

[22] KERBL B, KOPANAS G, LEIMKÜHLER T, et al. 3D Gaussian Splatting for Real-Time Radiance Field Rendering[J/OL]. ACM Transactions on Graphics, 2023, 42(4): 139:1-139:14. DOI: 10.1145/3592433.

[23] LUITEN J, KOPANAS G, LEIBE B, et al. Dynamic 3D Gaussians: Tracking by Persistent Dynamic View Synthesis[C/OL]//2024 International Conference on 3D Vision (3DV). IEEE, 2024: 800-809. DOI: 10.1109/3dv62453.2024.00044.

[24] WU G, YI T, FANG J, et al. 4D Gaussian Splatting for Real-Time Dynamic Scene Rendering[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 20310-20320.

[25] YANG Z, GAO X, ZHOU W, et al. Deformable 3D Gaussians for High-Fidelity Monocular Dynamic Scene Reconstruction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 20331-20341.

[26] HUANG Y H, SUN Y T, YANG Z, et al. SC-GS: Sparse-Controlled Gaussian Splatting for Editable Dynamic Scenes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 4220-4230.

[27] PARK J, BUI M Q V, BELLO J L G, et al. SplineGS: Robust Motion-Adaptive Spline for Real-Time Dynamic 3D Gaussians from Monocular Video[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 26866-26875.

[28] QUAN J, MIAO Q, XU Y, et al. ParticleGS: Learning Neural Gaussian Particle Dynamics from Videos for Prior-free Physical Motion Extrapolation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026: 8331-8341.

[29] LEI J, WENG Y, HARLEY A W, et al. MoSca: Dynamic Gaussian Fusion from Casual Videos via 4D Motion Scaffolds[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 6165-6177.

[30] WANG Q, YE V, GAO H, et al. Shape of Motion: 4D Reconstruction from a Single Video[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 9660-9672.

[31] YANG K, ZHANG X, HUANG Z, et al. MovingParts: Motion-based 3D Part Discovery in Dynamic Radiance Field[C]//International Conference on Learning Representations. 2024.

[32] GUO F, HSU C C, DING S, et al. Uncertainty Matters in Dynamic Gaussian Splatting for Monocular 4D Reconstruction[C]//International Conference on Learning Representations. 2026.

[33] WANG S, LEROY V, CABON Y, et al. DUSt3R: Geometric 3D Vision Made Easy[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 20697-20709.

[34] WANG J, CHEN M, KARAEV N, et al. VGGT: Visual Geometry Grounded Transformer[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 5294-5306.

[35] ZHANG J, HERRMANN C, HUR J, et al. MonST3R: A Simple Approach for Estimating Geometry in the Presence of Motion[C]//International Conference on Learning Representations. 2025.

[36] WANG Q, ZHANG Y, HOLYNSKI A, et al. Continuous 3D Perception Model with Persistent State [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 10510-10522.

[37] ZHANG C, LE MOING G, KOPPULA S, et al. Efficiently Reconstructing Dynamic Scenes One D4RT at a Time[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026: 7382-7392.

[38] GAO H, LI R, TULSIANI S, et al. Monocular Dynamic View Synthesis: A Reality Check[C/OL]// Advances in Neural Information Processing Systems: Vol. 35. Curran Associates, Inc., 2022: 33768-33780. DOI: 10.52202/068431-2447.

[39] DOERSCH C, GUPTA A, MARKEEVA L, et al. TAP-Vid: A Benchmark for Tracking Any Point in a Video[C/OL]//Advances in Neural Information Processing Systems: Vol. 35. Curran Associates, Inc., 2022: 13610-13626. DOI: 10.52202/068431-0989.

[40] KOPPULA S, ROCCO I, YANG Y, et al. TAPVid-3D: A Benchmark for Tracking Any Point in 3D [C/OL]//Advances in Neural Information Processing Systems: Vol. 37. Curran Associates, Inc., 2024: 82149-82165. DOI: 10.52202/079017-2611.

[41] ZHENG Y, HARLEY A W, SHEN B, et al. PointOdyssey: A Large-Scale Synthetic Dataset for Long-Term Point Tracking[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 19855-19865.

[42] SAVOSTYANOV D. World Models and Simulation: Research Landscape and Publication Activity [EB/OL]. 2026.

[43] HAFNER D, LILLICRAP T, FISCHER I, et al. Learning Latent Dynamics for Planning from Pixels [C]//Proceedings of the 36th International Conference on Machine Learning: Vol. 97. PMLR, 2019: 2555-2565.

[44] HAFNER D, LILLICRAP T, BA J, et al. Dream to Control: Learning Behaviors by Latent Imagination[C]//International Conference on Learning Representations. 2020.

[45] SCHRITTWIESER J, ANTONOGLOU I, HUBERT T, et al. Mastering Atari, Go, chess and shogi by planning with a learned model[J/OL]. Nature, 2020, 588(7839): 604-609. DOI: 10.1038/s41586-020-03051-4.

[46] CHUA K, CALANDRA R, MCALLISTER R, et al. Deep Reinforcement Learning in a Handful of Trials using Probabilistic Dynamics Models[C]//Advances in Neural Information Processing Systems: Vol. 31. Curran Associates, Inc., 2018.

[47] HANSEN N, SU H, WANG X. TD-MPC2: Scalable, Robust World Models for Continuous Control [C]//International Conference on Learning Representations (ICLR). 2024.

[48] FENG F, ZHENG Y, FU M, et al. Learning Task-Sufficient World Models by Synergizing Agentic Exploration and Structured Modeling[C]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 30616-30641.

[49] ASSRAN M, DUVAL Q, MISRA I, et al. Self-Supervised Learning From Images With a Joint-Embedding Predictive Architecture[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 15619-15629.

[50] KIPF T, ELSAYED G F, MAHENDRAN A, et al. Conditional Object-Centric Learning from Video [C]//International Conference on Learning Representations. 2022.

[51] WU Z, DVORNIK N, GREFF K, et al. SlotFormer: Unsupervised Visual Dynamics Simulation with Object-Centric Models[C]//International Conference on Learning Representations. 2023.

[52] ZHOU G, PAN H, LECUN Y, et al. DINO-WM: World Models on Pre-trained Visual Features enable Zero-shot Planning[C]//Proceedings of the 42nd International Conference on Machine Learning: Vol. 267. PMLR, 2025: 79115-79135.

[53] ASSRAN M, BARDES A, FAN D, et al. V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning[EB/OL]. Meta AI Research, 2025.

[54] MORBITZER N, EVERS J, SAVKIN A, et al. Future Dynamic 3D Reconstruction: Toward 3D World Modeling with Disentangled Ego-Motion[C]//Proceedings of the 43rd International Conference on Machine Learning: Vol. 306. PMLR, 2026: 90232-90250.

[55] LILLEMARK H, HUANG B, ZHAN F, et al. Flow Equivariant World Models: Structured Memory for Dynamic Environments[C]//Proceedings of the 43rd International Conference on Machine Learning: Vol. 306. PMLR, 2026: 73968-74002.

[56] SEO Y, KIM J, JAMES S, et al. Multi-View Masked World Models for Visual Robotic Manipulation[C]//Proceedings of the 40th International Conference on Machine Learning: Vol. 202. PMLR, 2023: 30613-30632.

[57] BRUCE J, DENNIS M, EDWARDS A, et al. Genie: Generative Interactive Environments[C]// Proceedings of the 41st International Conference on Machine Learning: Vol. 235. PMLR, 2024: 4603-4623.

[58] VALEVSKI D, LEVIATHAN Y, ARAR M, et al. Diffusion Models Are Real-Time Game Engines [EB/OL]. 2024.

[59] Google DeepMind. Genie 2: A Large-Scale Foundation World Model[EB/OL]. Google DeepMind, 2024.

[60] WANG X, ZHU Z, HUANG G, et al. DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving[C]//European Conference on Computer Vision. 2024.

[61] ZHAO G, WANG X, ZHU Z, et al. DriveDreamer-2: LLM-Enhanced World Models for Diverse Driving Video Generation[C/OL]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 39. 2025: 10412-10420. DOI: 10.1609/aaai.v39i10.33130.

[62] ZHANG K, TANG Z, HU X, et al. Epona: Autoregressive Diffusion World Model for Autonomous Driving[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 27220-27230.

[63] HADSELL R, RIVAS D, QI H. Genie 4: A New Generation of World Simulation[EB/OL]. Google DeepMind, 2026.

[64] WU R, HE X, CHENG M, et al. Infinite-World: Scaling Interactive World Models to 1000-Frame Horizons via Pose-Free Hierarchical Memory[C]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 135994-136007.

[65] SANCHEZ-GONZALEZ A, GODWIN J, PFAFF T, et al. Learning to Simulate Complex Physics with Graph Networks[C]//Proceedings of the 37th International Conference on Machine Learning: Vol. 119. PMLR, 2020: 8459-8468.

[66] ZHENG W, CHEN W, HUANG Y, et al. OccWorld: Learning a 3D Occupancy World Model for Autonomous Driving[C]//European Conference on Computer Vision. 2024.

[67] YANG Z, LIU Z, LU Y, et al. GenieDrive: Towards Physics-Aware Driving World Model with 4D Occupancy Guided Video Generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026: 35680-35690.

[68] LU G, JIA B, LI P, et al. GWM: Towards Scalable Gaussian World Models for Robotic Manipulation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 9263-9274.

[69] GARCIN S, WALKER T, MCDONAGH S, et al. Beyond Pixel Histories: World Models with Persistent 3D State[C]//Proceedings of the 43rd International Conference on Machine Learning: Vol. 306. PMLR, 2026: 34048-34070.

[70] JIANG C, ZHOU D, LIU J, et al. VectorWorld: Efficient Streaming World Model via Diffusion Flow on Vector Graphs[C]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 53507-53543.

[71] 李浩然, 陈宇辉, 崔文博, 等. 面向具身操作的视觉–语言–动作模型综述[J/OL]. 自动化学报, 2026, 52(1): 18-51. DOI: 10.16383/j.aas.c250394.

[72] ZITKOVICH B, YU T, XU S, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C]//Proceedings of The 7th Conference on Robot Learning: Vol. 229. PMLR, 2023: 2165-2183.

[73] KIM M J, PERTSCH K, KARAMCHETI S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[C]//Proceedings of The 8th Conference on Robot Learning: Vol. 270. PMLR, 2025: 2679-2713.

[74] CHI C, XU Z, FENG S, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion [J/OL]. The International Journal of Robotics Research, 2025, 44(10–11): 1684-1704. DOI: 10.1177/02783649241273668.

[75] BLACK K, BROWN N, DRIESS D, et al. π_0: A Vision-Language-Action Flow Model for General Robot Control[C/OL]//Proceedings of Robotics: Science and Systems. 2025. DOI: 10.15607/RSS.2025.XXI.010.

[76] LI X, LIU M, ZHANG H, et al. Vision-Language Foundation Models as Effective Robot Imitators [C]//International Conference on Learning Representations. 2024.

[77] SHRIDHAR M, MANUELLI L, FOX D. Perceiver-Actor: A Multi-Task Transformer for Robotic Manipulation[C]//Proceedings of The 6th Conference on Robot Learning: Vol. 205. PMLR, 2023: 785-799.

[78] GOYAL A, BLUKIS V, XU J, et al. RVT-2: Learning Precise Manipulation from Few Demonstrations[C/OL]//Proceedings of Robotics: Science and Systems. 2024. DOI: 10.15607/RSS.2024.XX.055.

[79] LI P, CHEN Y, WU H, et al. BridgeVLA: Input-Output Alignment for Efficient 3D Manipulation Learning with Vision-Language Models[C/OL]//Advances in Neural Information Processing Systems: Vol. 38. Curran Associates, Inc., 2025: 63635-63673. DOI: 10.52202/085713-2137.

[80] CEN J, YU C, YUAN H, et al. WorldVLA: Towards Autoregressive Action World Model[EB/OL]. 2025. arXiv:2506.21539.

[81] YE S, GE Y, ZHENG K, et al. World Action Models are Zero-shot Policies[EB/OL]. 2026. arXiv:2602.15922.

[82] WALKE H R, BLACK K, ZHAO T Z, et al. BridgeData V2: A Dataset for Robot Learning at Scale [C]//Proceedings of Machine Learning Research: Vol. 229 Proceedings of the 7th Conference on Robot Learning. PMLR, 2023: 1723-1736.

[83] KHAZATSKY A, PERTSCH K, NAIR S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[C/OL]//Proceedings of Robotics: Science and Systems. 2024. DOI: 10.15607/RSS.2024.XX.120.

[84] JAMES S, MA Z, ARROJO D R, et al. RLBench: The Robot Learning Benchmark & Learning Environment[J/OL]. IEEE Robotics and Automation Letters, 2020, 5(2): 3019-3026. DOI: 10.1109/LRA.2020.2974707.

[85] LIU B, ZHU Y, GAO C, et al. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning[C/OL]//Advances in Neural Information Processing Systems: Vol. 36. Curran Associates, Inc., 2023: 44776-44791. DOI: 10.52202/075280-1939.

[86] MEES O, HERMANN L, ROSETE-BEAS E, et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks[J/OL]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334. DOI: 10.1109/LRA.2022.3180108.

[87] NASIRIANY S, MADDUKURI A, ZHANG L, et al. RoboCasa: Large-Scale Simulation of Household Tasks for Generalist Robots[C/OL]//Proceedings of Robotics: Science and Systems. 2024. DOI: 10.15607/RSS.2024.XX.050.

[88] MU Y, CHEN T, CHEN Z, et al. RoboTwin: Dual-Arm Robot Benchmark with Generative Digital Twins[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 27649-27660.

[89] LI X, HSU K, GU J, et al. Evaluating Real-World Robot Manipulation Policies in Simulation[C]// Proceedings of The 8th Conference on Robot Learning: Vol. 270. PMLR, 2025: 3705-3728.

[90] KAELBLING L P, LITTMAN M L, CASSANDRA A R. Planning and acting in partially observable stochastic domains[J/OL]. Artificial Intelligence, 1998, 101(1–2): 99-134. DOI: 10.1016/S0004-3702(98)00023-X.